technische universität
dortmund

fakultät für informatik

Masterarbeit

Zeit-effizientes Training von Convolutional Neural Networks

Jessica Buehler

23. Dezember 2020

Gutachter:

Prof. Dr. Heinrich Müller

M.Sc. Matthias Fey

Lehrstuhl VII
Informatik
TU Dortmund

Inhaltsverzeichnis

Todo list

Mathematische Notation

Notation	Bedeutung
$\mathbf{x_i}$	Eingabe in das Netz
$\mathfrak{B}$	Menge der Batches des Datensatzes $\mathfrak{B} = \{\mathcal{B}_1, \dots \mathcal{B}_k\}$
$\mathcal{B}$	ein Batch mit m Elemente $\mathcal{B} = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$
$\mathbf{u}_{i,j}$	Ausgabe der Faltungsschicht j wobei in das Netz $\mathbf{x}_i$ eingegeben wurde.
$\mathbf{v}_{i,j}$	Ausgabe der Batchnormalisierungsschicht j wobei in das Netz $\mathbf{x}_i$ eingegeben wurde.
$\mathcal{W}$	Gewichte der Schichten $\mathcal{W} = \{W_1, \dots, W_J\}$ geordnet nach Stelle der Schicht im Vorwärtsdurchgang.
$\mathcal{W}^k$	Gewichte des k-ten Trainingsdurchlaufs
$f(\mathbf{x_i}, \mathcal{W})$	Funktion, die das CNN berechnet. $f(\mathbf{x}_i, \mathcal{W})$ berechnet eine Klassenzugehörigkeit für $\mathbf{x}_i$
y_i	tatsächliche Klasse von $\mathbf{x}_i$
$l(f(\mathbf{x_i}, \mathcal{W}), y_i)$	Funktion, die das CNN berechnet

1 Einleitung

In diesem Kapitel wird zunächst die Motivation und das Ziel dieser Arbeit in Kapitel 1.1 erläutert. In Kapitel 1.2 werden die Ergebnissen dieser Arbeit kurz vorgestellt. Abschliessend wird in Kapitel 1.3 ein Überblick über den Aufbau dieser Arbeit gegeben.

1.1 Motivation und Ziel dieser Arbeit

Wird die Zeit-Effizienz des Trainings eines Convolutional Neural Networks betrachtet, so ist die Betrachtung mehrerer Größen möglich. Es kann gemessen werden, wie lange eine Epoche des Netzes trainiert. Außerdem kann gemessen werden, wieviel Trainingszeit beziehungsweise Durchgänge gebraucht werden, bis die Hyperparameter gefunden wurde, die ein zufriedenstellendes Ergebnis für die Testdaten ergeben. Im Rahmen dieser Arbeit soll evaluiert werden, welche Möglichkeiten es gibt, um den Prozess des Findens diser Hyperparameter zu automatisieren und damit zu beschleunigen. Ohne diese Automatisierung muss nach jeden Trainingsdurchgang, bei nicht zufriedenstellenden Ergebnissen, manuell eine Anpassung der Hyperparmeter erfolgen.
Ein bestehendes Konzept, welches diesen Ansatz bereis verfolgt ist das „schnelle Ressourcen beschränkte Strukturllernen tiefer Netzwerke“, kurz MorphNet. Mit MorphNet wird mittels zwei konkurierender Verfahren die Struktur des Netzes bestimmt. Die konkurierenden Verfahren sind das Breiter machen des gesamten Netzes mittels eines Breitenmultiplikator und das Beschneiden des Netzes mit Hilfe eines Regulierers.
Neben diesem Verfahren wird ein eigenes Konzept erarbeitet für ein alternatives Verfahren, mit ebenfalls zwei konkurierenden Verfahren. Der Vorteil dieses alternativen Verfahrens gegenüber MorphNet ist, das neben der Breite auch die Tiefe des Netzes geändert werden kann. In diesem neuen Verfahren wird als beschneidende Methode PruneTrain benutzt, welches zusätzlich zum Trainingsfehler auch die Gewichte zusammenhängender Kanäle gemeinsam minimiert. PruneTrain hat

den Vorteil, dass auch ganze Blöcke des verwendeten ResNet entfernt werden können. Als vergrösserndes Verfahren wird Net2Net benutzt. Net2Net arbeitet mit drei Operatoren, einen der das Netz breiter macht und zwei, die das Netz tiefer machen. Dabei werden die zuätzlichen Gewichte so initialisiert, dass das Netz approximativ die gleiche Funktion berechnet.

1.2 Ergebnisse der Arbeit

MorphNet zeigt bei der Evaluierung auf einem Resnet mit dem Datensatz Cifar10 Schwächen. Diese Schwächen liegen sowohl bei fehlender Flexibilität, was die Tiefe des Netzes angeht als auch beim Umgang mit einem nicht stabil trainierenden Netz.
Die Evaluierung von PruneTrain zeigt, dass bei einfachem Beschendeiden des Netzes keine Trainingszeit gespart werden kann. Um hier beim Trainieren Zeit zu sparen, bei gleicher Speicherauslastung muss mit dem Beschendien des Netzes auch die Batchgröße erhöht werden. Eine weitere Erkenntnis ist, dass in der Regel ein Gewinn an Trainingszeit mit einem Verlust an Accuracy einhergeht.
Bei Net2Net zeigte sich, dass ein flacheres oder schmaleres Netz die Instabilität beim Training verringern kann. Mit Anwendung eines Operators, der das Netz breiter oder tiefer macht wird diese Stabilität erhalten. Der Operator für ein breiteres Netz schafft es, die Accuracy gegenüber einem genauso breiten ohne Änderung trainierten Netz zu verbessern. In der vorliegenden Evaluierungssituation schafft der Operator für ein tieferes Netz dies nicht.
Ergebnis von Net2Net room

Mit diesen Ergebnissen von PruneTrain und Net2Net hat das Konzept aus der Kombination dieser beiden das Potential besser als MorphNet zu werden.

1.3 Aufbau der Arbeit

In Kapitel 2 wird zunächst der aktuelle Stand der Wissenschaft erläutert. Zu diesem Zweck werden zunächst in Unterkapitel 3.1.3 die Grundlagen und Funktionsweisen eines CNNs erklärt. Die in dieser Arbeit verwendeten CNN-Architekturen ResNet und Inception werden darauf aufbauend in Unterkapitel 2.2.1 beschrieben. In Kapitel 2.3 wird eine Bibliometrie zum Thema der Arbeit vorgestellt. Dies ermöglicht dem Leser nachzuvollziehen wie das Fundament auf dem diese Arbeit beruht gefunden wurde.

In Kapitel 2.4 wird das Beschneiden des Netzes vorgestellt, welches das Netz von unwichtigen Gewichten befreien soll und so das Wachstum des Netzes in Grenzen halten soll. In Kapitel 2.5 werden die Operatoren vorgestellt, welche das Netz breiter beziehungsweise tiefer machen sollen.
In Kapitel 2.6 wird ein Überblick über das Thema der automatischen Architektursuche gegeben, um das Strukturlernen des Netzes im Kontext seiner Forschungsrichtung zu betrachten. In Kapitel 2.7 wird die Vergleichsmethode vorgestellt, welche mit Hilfe von Strukturlernen versucht eine bessere Netzstruktur zu finden.
Experimente:3
Setup der Experimente 3.1
PruneTrain Experimente: 5
Net2Net Experimente: 6
MorphNet: 4
Net2Net + PruneTrain: **??**
Fazit: 7

2 Stand der Wissenschaft

Diese Kapitel soll dem Leser eine Übersicht über den aktuellen Stand der Wissenschaft geben. Zu diesem Zweck hat dieses Kapitel zwei Teile. Im ersten Teil wird zunächst grundlegend die Funktionsweise eines Convolutional Neural Networks (CNNs) erläutert. Im zweiten Teil des Kapitels wird ein Überblick über die bisherigen wissenschaftlichen Erkenntnisse im Themenbereich dieser Arbeit vorgetellt.

2.1 Funktionsweise eines CNN

Die Quelle für dieses Unterkapitel ist soweit nicht anders vermerkt ein Buch über „Deep Learning“ [GBC16].
CNNs sind spezielle neuronale Netze. Der Unterschied zu einem „Multilayer-Perzeptron (MLP)[1]“ ist, dass bei einem MLP jede Verbindung zwischen Neuronen und die Neuronen selbst ein eigenes trainierbares Gewicht haben. Aus diesen trainierbaren Werten wird mittels einer Matrixmultiplikation mit den Eingabedaten bzw. den Daten der vorherigen Schicht die Ausgabe jedes Neurons berechnet. Im Gegensatz dazu sind CNNs neuronale Netze, die in mindestens einer ihrer Schichten die Faltung anstelle der allgemeinen Matrixmultiplikation verwenden.
Dies bedeutet, dass die Eingabedaten für ein CNN für diese Faltung geeignet sein muss. Geeignet für die Faltung sind Eingabedaten, die gridförmig angeordnet sind. Bilddaten sind ein grosser Anwendungsbereich für CNNs.
Bei der Faltung wird auf die Eingabedaten beziehungsweise die Daten der vorherigen Schicht ein Kernel angewendet.
In Abbildung 2.1 ist zu sehen wie die Faltung auf einem Bild durchgeführt wird. Der Kernel wird auf jedes Teilbild mit der Grösse des Kernels angewendet. Die korrespondierenden Felder werden multipliziert und alle entstehenden Produkte werden addiert. So entsteht aus der Faltung des Kernels mit der Eingabe in die

[1] Die Hintergründe des MLPs und allgemein neuronaler Netzwerke werden hier nicht behandelt. Für eine Einführung in neuronale Netzwerke kann aber [Hay98] herangezogen werden

entsprechende Schicht eine Merkmalskarte.

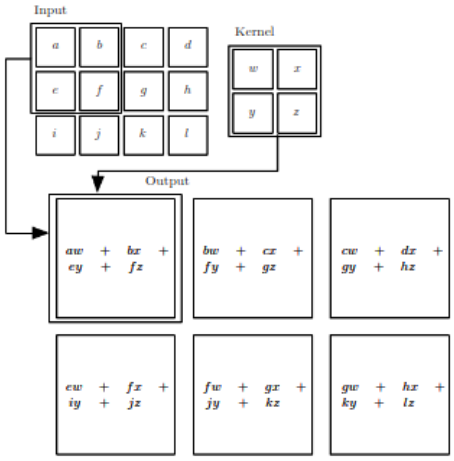

Abbildung 2.1: Abbildung zur Faltung [GBC16]

Mehrere dieser Kernel bilden zusammen ein Teil des Convolutional Layer. Dabei wird die Merkmalskarte des Eingangs des Layers wie in Abbildung 2.2 gezeigt auf jeden Kernel mit einer Faltung angewendet. Durch diese Faltung entstehen erste Merkmalskarten. Diese Merkmalskarten werden im nächsten Schritt komponentenweise als Eingabe für eine Aktivierungsfunktion benutzt. In Abbildung 2.2 wird eine Rectified Linear Unit (ReLU) als Aktivierungsfunktion benutzt[2].
Um die Größe der Merkmalskarte zu reduzieren kann nach dem Anwenden der Aktivierungsfunktion eine Pooling Operation eingeführt werden. Durch die Verkleinerung der Merkmalskarte wird es weniger wichtig wo genau ein Merkmal in den Daten autaucht. Für ein Feld in der Ausgabe der Pooling Operation ist der Bereich, der von diesem Feld wahrgenommen wird, größer als ohne die Pooling Operation. Ein Nebeneffekt des Poolings ist die Vermeidung beziehungsweise Verringerung von Overfitting.
Der Begriff Padding aus Abbildung 2.2 enthält einen Wert, der aussagt, ob und wenn 'ja' wieviele Pixel um das eigentlich Bild gelegt werden. Dies geschieht, um dem Kernel die Möglichkeit zu geben, die Pixel am Rand des Bildes (bzw. der Merkmalskarte der vorherigen Schicht) in mehreren Teilbildern zu verarbeiten.
Beim Anwenden des Kernels auf der Eingabe kann jedes Teilbild genutzt werden oder es können Teilbilder ausgelassen werden. Dies wird über den Parameter Stride kommuniziert. Beim Stride von Eins wird jedes Teilbild verwendet. Wird der Stride auf Zwei gesetzt, so wird nach jedem verwendetem Teilbild eines ausgesetzt.

[2]Für Erklärung ReLU siehe [Hay98]

In einem CNN werden mehrere dieser Convolutional Layer hintereinander geschaltet, um komplexe Features erkennen zu können.

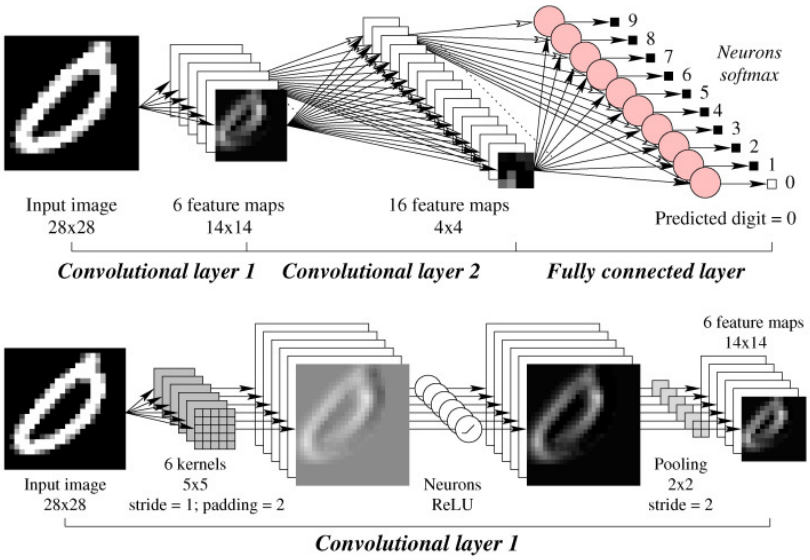

Abbildung 2.2: Convolutional Neural Net [CCGS16]

Eine beispielhafte Übersicht über die CNN-Architektur ist in Abbildung 2.2 zu sehen.

Die voll verbundene Schicht errechnet aus den Ausgängen der Convolutional-Layer, in welche Klasse ein Objekt klassifiziert werden soll.

Die Kernel, die auf die Merkmalskarte bzw. die Eingabebilder angewendet werden, sind trainierbar. Zusätzlich sind auch die Gewichtungen der voll verbundenen Schicht trainierbar. Das heißt, durch den Trainingsprozess wird versucht die Werte in der Kernelmatrix und der voll verbundenen Schicht so zu verändern, dass das gesamte CNN besser klassifizieren kann.

Die Trainingsdaten sind Daten aus dem Datensatz, die bereits klassifiziert sind. Diese Trainingsdaten werden in Batches aufgeteilt. Der Trainingsprozess beginnt mit der aufeinanderfolgenden Eingabe der Bilder $\mathbf{x}_i$ eines Batches von Trainingsdaten in die erste Schicht. In jeder Schicht des Netzes wird mit der Eingabe aus der vorherigen Schicht weitergerechnet. Die Ausgabe einer Faltungsschicht wird $\mathbf{u}_{i,j}$ angegeben, wobei i für den Platz im jeweiligen Batch steht und j für die Nummer der entsprechenden Schicht. In der letzten, voll verbundenen Schicht ist das Ergebnis eines einzelnen Bildes die Klasse, die durch die aktuellen Belegung der Gewichte des Netzes klassifiziert wird. Die Gewichte der Schichten werden mit W_j bezeichnet, wobei j die Schicht der Gewichte angibt. Alle Gewichte des

Netzwerkes werden mit $\mathcal{W}$ bezeichnet, wobei

$$\mathcal{W} = \left\{W^1, \dots W^J\right\} \tag{2.1}$$

die Definition dieser Menge ist.
Diese Klassifikation ist formal eine Funktion f mit der Eingabe $\mathbf{x}_i$. Da das Bild $\mathbf{x}_i$ bereits vorher klassifiziert wurde, hat es ein Label y_i, welches die Klasse von $\mathbf{x}_i$ angibt. Mit Hilfe das Labels und der Ausgabe von $f(\mathbf{x}_i, \mathcal{W})$ wird eine Verlust-Funktion $l(f(\mathbf{x}_i, \mathcal{W}), y_i)$ berechnet. Die Verlust-Funktion berechnet wie weit die tatsächliche Klasse y_i von der Ausgabe des Netzes $f(\mathbf{x}_i, \mathcal{W})$ entfernt ist. Aus der Anzahl an falsch klassifizierten Trainingsbildern wird berechnet, wie hoch der prozentuale Fehler ist. Dieser wird Trainingsfehler genannt.
Die Ableitung dieser Verlust-Funktion wird rückwärts durch das Netz propagiert und damit ein Gradient berechnet. Mittels des Gradientenabstiegsverfahrens wird die Verlust-Funktion minimiert, was dazu führt, dass das Netz die Trainingsbilder besser klassifiziert.
Im Anschluss an diesen Trainingsprozess können Bilder, die ohne zugehöriges Label in das Netz eingegeben werden, klassifiziert werden. Um die Klassifikationsleistung für unbekannte, nicht im Trainingsprozess benutzte Bilder zu testen, wird eine Menge an diesen Bilder durch das Netz klassifiziert und die Fehlerrate gemessen. Dieser Fehler wird Test-Fehler genannt.
Mit Hilfe des Trainings- und Testfehlers lässt sich die Klassifikationsleistung des Netzes beurteilen. Sind beide Fehlerarten hoch, so muss das Netz entweder noch weiter trainieren oder an der Struktur beziehungsweise den Hyperparametern muss etwas geändert werden. Ist jedoch nur der Testfehler hoch, so ist die Generalisierungsfähigkeit des Netzes nicht gut.
Eine weitere Technik, die zur Verbesserung der Generalisierungsfähigkeit führen kann ist die Batchnormalisierung. Diese Technik wird zum Ende dieses Unterkapitels betrachtet [IS15]. Beim Training eines CNNs ändert sich die Verteilung der Eingabewerte während des Trainings durch Veränderung der Gewichte der vorherigen Schicht. Dies führt zu einem langsameren Training, da es kleinere Lernraten hat und damit mehr Durchläufe braucht damit das Netz konvergiert. Dieses Phänomen wird interne Kovarianzeverschiebung genannt und durch eine Normalisierung gelöst. In Algorithmus 2.1 ist zu sehen, wie dies schrittweise geschieht.
Zunächst bekommt die Batchnormalisierungsschicht die Eingabewerte $u_{i,j}$, wobei j die Nummer der entsprechenden Schicht angibt und i angibt welches Element

in der jeweiligen Batch $\mathcal{B}$ gemeint ist. Zunächst wird aus allen Elementen des aktuellen Batches $\mathcal{B}$ der Mittelwert $\mu_{i,\mathcal{B}}$ berechnet. Mit Hilfe dieses Wertes wird im nächsten Schritt die Varianz des Batches $\mathcal{B}$ berechnet. Diese beiden Werte werden benutzt, um Elemente des Batches $\mathcal{B}$ so zu normalisieren, dass der Batch einen Mittelwert von Null und eine Varianz von Eins hat. Der in dieser Formel aufgeführte Wert ϵ wird zur quadratischen Varianz addiert um zusätzliche numerische Stabilität zu gewähren.
Im Anschluss an diese Normalisierung lassen sich die Elemente des Batches durch eine weitere mit trainierbaren Gewichten versehenen Transformation verändern. Da diese Parameter γ und β durch diese Transformation Teil des Modells sind und stetig differenzierbar sind, lassen sie sich in den Trainingsprozess integrieren.

Eingabe: Werte von $\mathbf{u}_{i,j}$, j-te Schicht und i-tes Element der Menge der Trainingsdaten eines Batches $\mathcal{B}$, zu trainierende Parameter γ, β
Ausgabe: $\left\{\mathbf{v}_{(i,j)} = \mathrm{BN}_{\gamma,\beta}(u_{i.j}\right\}$

$$\mu_{i,\mathcal{B}} \leftarrow \frac{1}{m}\sum_{j=1}^{m}\mathbf{u}_{i,j}$$

$$\sigma^2_{i,\mathcal{B}} \leftarrow \frac{1}{m}\sum_{j=1}^{m}\left(\mathbf{u}_{i,j} - \mu_{i,\mathcal{B}}\right)^2$$

$$\hat{\mathbf{u}}_{i,j} \leftarrow \frac{\mathbf{u}_{i,j} - \mu_{i,\mathcal{B}}}{\sqrt{\sigma^2_{i,\mathcal{B}} + \epsilon}}$$

$$\mathbf{v}_{i,j} \leftarrow \gamma\hat{\mathbf{u}}_{i,j} + \beta = \mathrm{BN}_{\gamma,\beta}(\mathbf{u}_{i,j})$$

Algorithmus 2.1: Batchnormalisierungs-Algorithmus

2.2 CNN- Architekturen

3.1.3

2.2.1 ResNet – eine neuere CNN-Architektur

Die wachsende Tiefe bei CNN-Architekturen geschieht mit dem Hintergrund, dass tiefere Netze größere Modellkomplexität haben. Die klassische CNN-Architektur

mit hintereinander geschalteten Conv-Layern schafft es bei wachsender Tiefe des Netzes nicht, diese Komplexität in bessere Klassifikationsleistung umzusetzen. Die Quelle zu diesem Unterkapitel ist das Paper, welches wegweisend für die Verwendung von Residualen Netzen in der Wissenschaft ist [HZRS15].
Neuere CNN-Architekturen schaffen es, dieses Problem zu vermeiden. Eine dieser neueren Architekturen ist das ResNet. Das ResNet ist ein Residualnetz, welches Kurzschlussverbindungen einführt. In Abbildung 2.3 ist zu sehen wie eine Kurzschlussverbindung aussieht. Durch die Kurzschlussverbindungen in den einzelnen Blöcken ist es für das Netzwerk einfacher, Funktionsbestandteile, die ähnlich einer Idenditätsfunktion sind, zu erlernen.

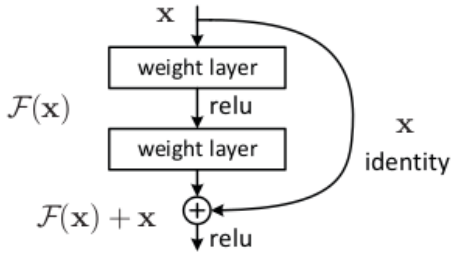

Abbildung 2.3: Abbildung der Kurzschlussverbindung [HZRS15]

Vermieden wird damit im Vergleich zu einem klassischen CNN das Problem des verschwindenden Gradienten. Bei einem klassischen CNN wird mit der letzten Schicht begonnen und der Gradient wird durch die Kettenregel bis zur ersten Schicht berechnet. Je tiefer das Netz wird, desto kleiner werden die Veränderungen des Gradienten für die ersten Schichten. Die Gewichte konvergieren dann sehr langsam bzw. teilweise gar nicht mehr in die gewünschte Richtung.
Residuale Netze vermeiden dies, indem sie aus vielen kleineren Netzen bestehen. Hier wird der Gradient nicht auf einer Linie zur Eingangsschicht zurück propagiert, sondern auch über die Kurzschlussverbindungen. So entsteht ein Netz, welches sehr viel tiefer sein kann ohne die Probleme des verschwindenden Gradienten zu haben. Durch den Wegfall dieses Problems lassen sich mit residualen Netzen bessere Traningsfehler und Testfehlerraten erreichen.
Eine weitere Technik, die in residualen Netzen verwendet wird, ist die der Bottleneck-Blocks. Dies resultiert aus dem Problem der stark steigenden Trainingszeiten, je breiter die Blöcke sind. Ein Bottleneck-Block ist in Abbildung 2.4a abgebildet.
Die erste Schicht im Bottleneck-Block reduziert dabei die Größe der Feature-Map. Dies hat zur Folge, dass die Durchlaufzeit des mittleren Convolutional Layers geringer ist als bei einem äquivalenten Nicht-Bottleneck-Block. Der letzte Layer

des Blockes stellt die Größe vor dem Block wieder her.

Ein von der Zeitkomplexität ähnlicher Block wie der Block in Abbildung 2.4a ist in Abbildung 2.4b zusehen. Wird in einem residualen Netz mit 34 Schichten aus Blöcken wie in Abbildung 2.4b jeder Block durch einen Block wie in Abbildung 2.4a ausgetauscht, so entsteht ein 50 schichtiges residuales Netzwerk mit einer durchschnittlich erhöhten Accuracy.

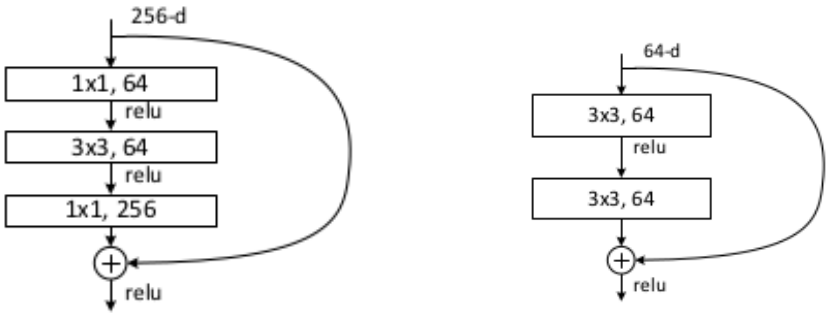

(a) Bottleneck **(b)** Nicht-Bottleneck

Abbildung 2.4: Vergleich zweier Residual-Netz-Blöcke [HZRS15]

2.2.2 Inception

Inception ist eine CNN- Architektur, die sowohl in der Morph-Net Veröffentlichung als auch in der Net2Net- Veröffentlichung verwendet wurden. Um die Ergebnisse aus den Veröffentlichungen mit den eigenen vergleichen zu können wird hier die Inception Architektur vorgestellt. Soweit nicht explizit anders erwähnt ist die Quelle zu diesem Unterkapitel die Inception Veröffentlichung [**?**].

Beim Versuch ein CNN zu verbessern wird in der Regel das Netz vergrössert, das heißt es werden entweder mehr Schichten benutzt oder das die einzelnen Schichten des Netzes sind breiter. Dies kann zwar eine verbesserte Accuracy bringen sorgt aber auch für ein höheren Berechnungs- und damit Zeitaufwand. Außerdem ist ein grösseres Netzwerk mit mehr Parametern auch mehr anfällig für Overfitting.

Das Inception Netz ist eine Architektur, die ohne diese Nachteile eine bessere Architektur schaffen will.

2.3 Vorgehen zur Suche nach dem Stand der Wissenschaft

Eine Google-Suche nach “time efficient training convolutional neural networks” ergibt ungefähr 12 Millionen Suchergebnisse. Mit dieser Flut an Ergebnissen und vielen populär-wissenschaftlichen Einträgen ist die Suche nicht erfolgreich. Aus diesem Grund wird die Suche auf die Seite arvix.org eingeschränkt. Diese Einschränkung macht Sinn mit dem Hintergrund, dass bereits 2017 über 60% Prozent der publizierten Paper auf arxiv.org als Preprint veröffentlicht wurden [SG17]. Diese Zahl ist seitdem weiter gestiegen, was die Zahl der veröffentlichten Paper im Bereich Machine Learning pro Tag in Abbildung 2.5 zeigt.

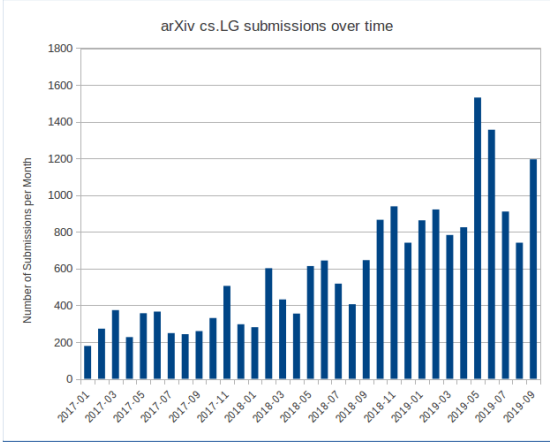

Abbildung 2.5: Tägliche Submissionen der Kategory Machine Learning auf arxiv [oA19]

Auch mit der auf arxiv.org eingeschränkten Suche ist die Menge an wissenschaftlichen Veröffentlichungen weiterhin zu groß für eine einzelne wissenschaftliche Arbeit. Zunächst wird eine Vorauswahl anhand des Themas der Arbeit getroffen. Es fallen alle Veröffentlichungen weg, die auf anderen Ausführungsplattformen als GPUs arbeiten. Aufgrund des schnellen Forschungsfortschritts und der Hardware sowie Softwareentwicklung liegt der Fokus auf Veröffentlichungen nach 2016.
Die nach diesen Einschränkungen gefundenen Paper sind in einer Mindmap in Abbildung 2.6 zu sehen. Mit blauer Schrift werden die Suchbegriffe dargestellt. Die einzelnen, aufgrund dieser Suchbegriffe gefundenen Paper werden mit grüner Schrift angezeigt. Mit roter Schrift werden die Paper dargestellt, die durch das Paper der vorherigen Ebene zitiert werden. Gelb hinterlegt sind Paper, die das Paper auf der vorherigen Ebene zitieren. In den weiteren Unterkapiteln werden die so gefundenen Paper vorgestellt und die verwendeten Methoden erklärt.

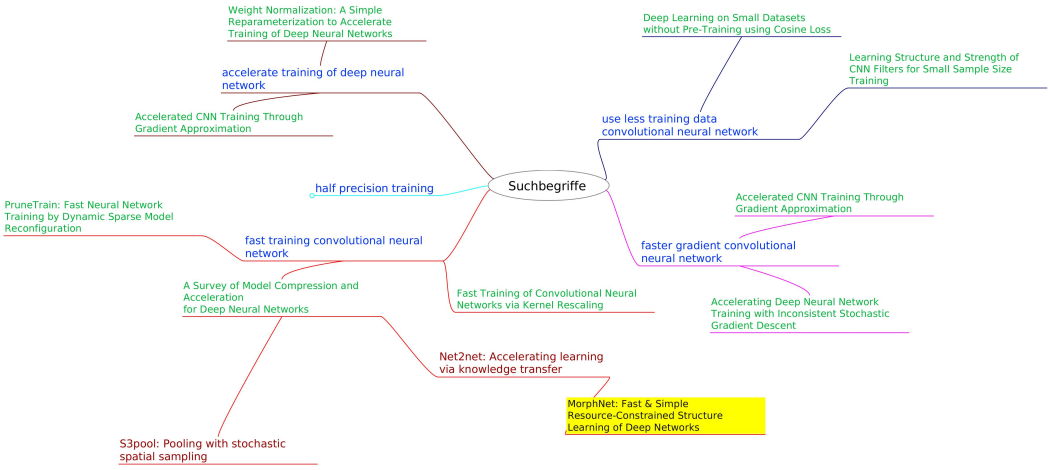

Abbildung 2.6: Mindmap zu den Suchbegriffen bezüglich des aktuellen wissenschaftlichen Stands

2.4 Beschneidung des Netzes zur Beschleunigung des Trainings

Das Beschneiden[3] des Netzes ist eine Technik, die entwickelt wurde um die Inferenzzeit eines neuronalen Netzwerks zu reduzieren. Das Beschneidungsverfahren wird auf das bereits trainierte Netz angewendet. Dabei wird entschieden, welche Gewichte nur einen minimalen oder keinen Effekt auf das Klassifikationsergebnis haben, um diese zu entfernen.

Das Beschneiden des Netzes kann auch verwendet werden um die Trainingszeit zu minimieren. Diese Methode soll hier in einem Unterkapitel erläutert werden. Als Quelle für das Unterkapitel dient ein Paper, welches evaluiert, inwiefern Trainingszeit mittels Beschneiden gespart werden kann [LCZ+19].

Das Ziel des Beschneidens während des Trainings ist es, die Gewichte einzelner Kanäle auf Null zu setzen und zu entfernen, um mit einem kleinerem Netz in den nachfolgenden Epochen Trainingszeit zu sparen. Dazu wird zu der Verlust-Funktion des Netzwerks ein Normalisierungsterm addiert. Damit die Gewichte ganzer Kanäle möglichst unter den Schwellwert fallen, werden die Gewichte der Kanäle gemeinsam quadriert, wie in der folgenden Gleichung zu sehen ist:

$$GL(\mathcal{W}) = \sum_{j=1}^{J} \left(\sum_{c_j=1}^{C_j} ||W_j(c_j, :, :, :)||_2 + \sum_{k_j=1}^{K_j} ||W_j(:, k_j, :, :)||_2 \right) \tag{2.2}$$

[3]Beschneiden wird hier äquivalent zum Englischen „to prune“ verwendet

Dieser Term nennt sich Gruppen-Lasso. Der Parameter W_j stellt die Gewichte im CNN als Tensor dar. Mit j wird dargestellt, um welche Schicht es sich handelt. Die Dimensionen des Tensors sind: Ausgangskanäle ×Eingangskanäle ×Kerneldimension 1 ×Kerneldimension 2. J gibt an, über wie viele Layer der Gruppen-Lasso-Term berechnet wird. k_j ist die Laufvariable über die einzelnen Eingangskanäle und c_j über die einzelnen Ausgangskanäle. Alternativ zum Gruppen-Lasso Regularisierer könnten hier auch andere Regularisierer, wie L1- bzw. L2-Regularisierer verwendet werden. Der Vorteil des Gruppen-Lasso Regularisierers ist, dass durch das gemeinsame Quadrieren der Gewichte einer Schicht diese gemeinsam minimiert werden.

Um das Verhältnis von Gruppen-Lasso-Term zur Verlust-Funktion dynamischer wählen zu können, werden diese nicht einfach miteinander addiert. Es wird abhängig von der Initialbelegung der Gewichte ein Parameter λ berechnet, der Gruppen-Lasso und Verlust-Funktion balanciert:

$$LPR\left(GL(\mathcal{W}), l(f(\mathbf{x}_i, \mathcal{W}), y_i)\right) = \frac{\lambda \cdot GL(\mathcal{W})}{l(f(\mathbf{x}_i, \mathcal{W}), y_i) + \lambda \cdot GL(\mathcal{W})} \tag{2.3}$$

Die Größe LPR ist hier zwischen Null und Eins wählbar. Je größer sie gewählt wird, desto größer ist der Anteil, der beschnitten wird. Regelmäßig werden während des Trainierens des Netzes Gewichte, die unter dem Schwellwert liegen auf Null gesetzt. Es entsteht ein nur dünn besetztes Netz. Dann wird durch ein Rekonfigurationsverfahren aus dem dünn besetzten Netz ein dicht besetztes Netz ohne die vorher nicht besetzten Kanäle. Um dieses Verfahren durchzuführen muss überprüft werden, ob mit dem Entfernen der Kanäle die Dimensionen der verschiedenen aufeinanderfolgenden Kanäle übereinstimmen. Bei einem residualen Netz muss zusätzlich darauf geachtet werden, dass die Dimensionen der Kurzschluss-Verbindungen zusammen passen.

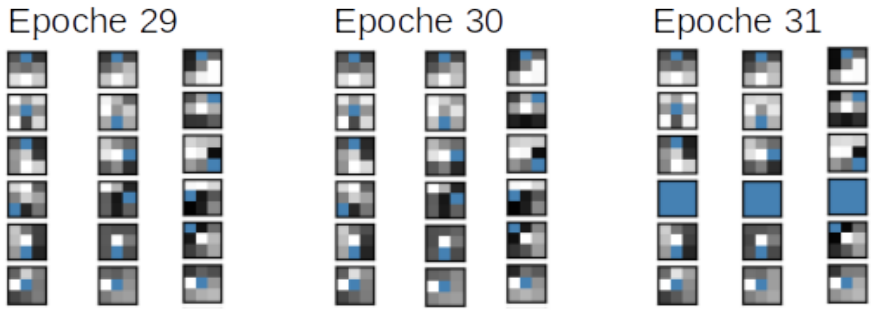

Abbildung 2.7: Beispielhafte Darstellung des Kanal-Union-Verfahrens

Zu diesem Zweck wird das Kanal-Union-Verfahren eingeführt. In Abbildung 2.8 wird beispielhaft ein Kanal-Union-Verfahren durchgeführt. Beim Kanal-Union-Verfahren wird eine Liste der Layer geführt, die aufeinander abgestimmt werden müssen. Im Falle eines residualen Netzes muss zusätzlich eine Liste der zusammengehörigen Layer der Kurzschlussverbindungen geführt werden. Im nächsten Schritt werden alle Eingangs- und Ausgangskanäle, die noch Gewichte größer Null haben in einer Liste gesammelt. Mit allen Elementen dieser Liste wird nun geprüft, ob mit Hilfe von Vereinigungen Kanäle gefunden werden können, die zwar keine von Null verschiedenen Gewichte mehr haben, wegen der Dimensionalität aber trotzdem beibehalten werden müssen. Alle Kanäle, die nicht unter diese Bedingung fallen, können mit Hilfe einer Rekonfiguration aus dem Netzwerk entfernt werden. In Abbildung 2.7 sind beispielhaft drei Eingangs- und sechs Ausgangskanäle dargestellt. In jedem Element des kartesischen Produkts der Menge der Eingangs- und Ausgangskanäle ist jeweils ein drei mal drei Felder großer Kernel dargestellt. Die Werte der Gewichte sind blau markiert, sobald sie absolut kleiner als der gewählte Grenzwert sind. Je dunkler die nicht-blauen Gewichte sind, desto kleiner sind sie. Da zwischen den jeweiligen Epochen für jede Batch eine Anpassung der Gewichte durchgeführt wird, entstehen teilweise große Veränderungen zwischen den Epochen. Dies ist zum Beispiel von Epoche 30 zu Epoche 31 im vierten Ausgangskanal sichtbar. Hier fällt innerhalb einer Epoche der Großteil des Ausgangskanal unter den Grenzwert.

Bei einem residualen Netzwerk kann weiterhin ein ganzer Block wegfallen. In diesem Fall müssen die Kanal-Union-Listen angepasst werden, die weitere Aktion wird ohne diesen Block im um mehrere Schichten verkürzten Netzwerk weiter geführt

Da mit dem Verkleinern des Netzes nicht nur potentiell Zeit sondern auch Speicherplatz gespart wird, kann bei gleicher Speicherauslastung die Batchgröße erhöht werden. Da die verwendete Technik für die Erhöhung der Batchgröße in der Quelle nicht angegeben ist und in der verwendeten Implementierung fehlt, wurde diese nachimplementiert. Dies wird in Kapitel **??** erläutert [ptI]. Hierbei wird die Lernrate an die erhöhte Batchgröße angepasst um negative Effekte für die Accuracy abzumildern oder auszuschließen.

Damit lassen sich Netzverkleinerungsraten von etwa 50 % erreichen bei weniger als 2 % Accuracy-Verlust auf dem Datensatz Cifar10. Andere Techniken schaffen zwar zwischen 70 - 80 % Netzverkleinerungsraten brauchen jedoch wesentlich mehr Trainingszeit [FC19]. Diese großen Verkleinerungsraten sind dort sehr stark

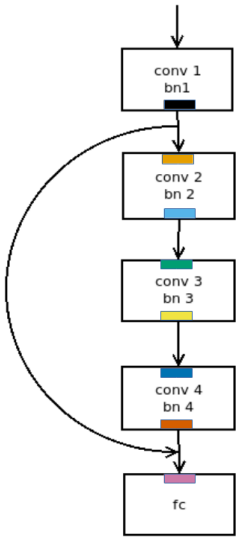

Liste der Layer, die direkt hintereinander sind und aufeinander abgestimmt werden müssen (ohne das zwischen den Layern eine Kurzschlussverbindung beginnt oder endet):
$H = \{(2, 3), (3, 4)\}$
Liste der Layer, die im Zusammenhang mit den Kurzschlussverbindungen die gleiche Eingangskanaldimension haben müssen:
$E = \{(2, \text{fc})\}$
Liste der Layer, die im Zusammenhang mit den Kurzschlussverbindungen die gleiche Ausgangskanaldimension haben müssen:
$A = \{(1, 4)\}$
Liste der dicht-besetzten Schichten vor dem ersten Beschneiden:
$1 : \{0, 1, 2\}, \{0,1,2,3,4,5,6,7\}$
$2 : \{0,1,2,3,4,5,6,7\}, \{0,1,2,3,4,5,6,7\}$
$3 : \{0,1,2,3,4,5,6,7\}, \{0,1,2,3,4,5,6,7\}$
$4 : \{0,1,2,3,4,5,6,7\}, \{0,1,2,3,4,5,6,7\}$
$fc : \{0,1,2,3,4,5,6,7\}, \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10\}$

Liste der dicht-besetzten (db) Schichten nach dem 'auf-Null-setzen' der Parameter aber vor der Rekonfiguration:
$1 : \{0, 1, 2\}, \{0,1,4,5,6,7\}$
$2 : \{0,1,3,5,6,7\}, \{0,1,2,4,5,6,7\}$
$3 : \{0,1,2,4,5,6,7\}, \{0,1,2,3,5,6,7\}$
$4 : \{0,1,3,4,6,7\}, \{0,1,3,4,5,6,7\}$
$fc : \{0,1,3,4,5,6\}, \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10\}$
Vorgehen des Kanal-Union-Verfahrens: Als erster Schritt wird für alle Elemente aus H die Vereinigung von Ausgangs- und Eingangskanälen berechnet und diese dann zugewiesen:
$2, 3 : A(2) \cup E(3) = \{0,1,2,4,5,6,7\} \cup \{0,1,2,4,5,6,7\} = \{0, 1, 2, 4, 5, 6, 7\}$
Hier wird der dünn-besetzte Kanal 3 entfernt
$3, 4 : A(3) \cup E(4) = \{0,1,2,3,5,6,7\} \cup : \{0,1,3,4,6,7\} = \{0, 1, 2, 3, 4, 5, 6, 7\}$
Der nullwertige Eingangskanal 5 von Schicht 4 wird nicht entfernt, da der dazugehörige Ausgangskanal von Schicht 3 nicht nullwertig ist. Im nächsten Schritt werden für die Elemente an jeweils gleicher Stelle aus den Mengen A und E Vereinigungen gebildet: $A(1) \cup A(4) \cup E(2) \cup E(\text{fc}) =$
$\{0,1,4,5,6,7\} \cup \{0,1,3,4,5,6,7\} \cup \{0,1,3,5,6,7\} \cup \{0,1,3,4,5,6\} =$
$\{0, 1, 3, 4, 5, 6, 7\}$
Hier wird in den Ausgangskanälen von Schicht 1 und 2 sowie in den Eingangskanälen von Schicht 2 und fc jeweils der 2. Kanal entfernt.

Abbildung 2.8: Beispielhafte Durchführung des Channel Union-Verfahrens

abhängig von der Initialisierung [FC19]. Das heißt, nur einzelne Initialisierungen führen zu so starken Verkleinerungsraten, was insgesamt zu einer längeren Trainingszeit führt [FC19].
Eine weitere Beschneidungstechnik arbeitet vor dem Training des Netzwerkes [TKYG20]. Damit wird das Netz abhängig von der Initialbelegung beschnitten. Es lassen sich zwar sehr große Teile der Parameter auf Null setzen, hierbei wird im Vergleich zur Beschneidungsmethode während des Trainings allerdings weder für gemeinsames Beschneiden von Kanälen gesorgt, noch wird ein Rekonfigurationsverfahren vorgestellt. Somit hat das Netz am Ende des Verfahrens zwar relativ viele auf Null gesetzte Parameter ist aber weder schneller noch kleiner.

2.5 Beschleunigung des Lernens durch Wissenstransfer

Beim Trainieren eines CNNs kommt es häufig vor, dass nach initialem Wählen der Tiefe beziehungsweise Breite des Netzes diese Parameter in einem weiteren Trainingslauf erhöht werden und in Folge dessen das Netzwerk komplett neu trainiert werden muss. Mit Hilfe der Quelle zu diesem Unterkapitel wurde ein Verfahren geschaffen, welches das Netz tiefer oder breiter machen kann und dabei die im ersten Trainingsdurchlauf trainierten Gewichte weiter verwendet [CGS15]. Durch diesen Wissenstransfer von einem Netz zu einem tieferen oder breiteren Netz wird eine schnellere Konvergenz des neuen Netzes erwartet. Durch die Initialisierung mit schon vorhandenen Parametern entsteht eine Transformation, die die erlernte Funktion erhält.

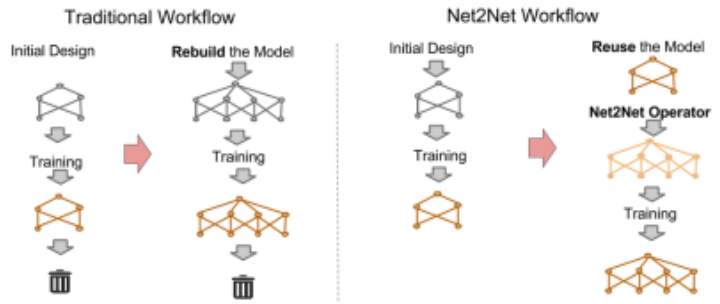

Abbildung 2.9: Traditioneller Workflow vs. Net2Net Workflow

Wie in Abbildung 2.9 abgebildet ist, lässt sich so der Arbeitsablauf zum Finden der passenden Netzstruktur anders gestalten. Der Net2Net-Operator macht hier

das Netz entweder breiter (mehr Kanäle in bestimmten Schichten) oder tiefer (zusätzliche Schichten). Diese beiden Operatoren werden nun vorgestellt.

Operator für breiteres Netz

Beim Operator für ein breiteres Netz werden für eine bestimmte Schicht Ausgangskanäle und für die nachfolgende Schicht Eingangskanäle hinzugefügt. Die Schicht, der die Ausgangskanäle hinzugefügt werden, wird mit j bezeichnet und hat den Gewichtstensor $\mathbf{W}_j$ mit der Dimensionalität von $n \times l \times d(h_{l,1}) \times d(h_{l,2}$. Die Schicht, der die Eingangskanäle hinzugefügt werden wird mit $j+1$ bezeichnet und hat den Gewichtstensor $\mathbf{W}_{j+1}$ mit der Dimensionalität von $m \times n \times d(h_{j+1,1}) \times d(h_{j+1,2})$. Dem Layer j werden q Kanäle hinzugefügt. Dies entspricht wie in Abbildung 2.10 abgebildet ist $q \cdot l$ zusätzlichen Filterkerneln.

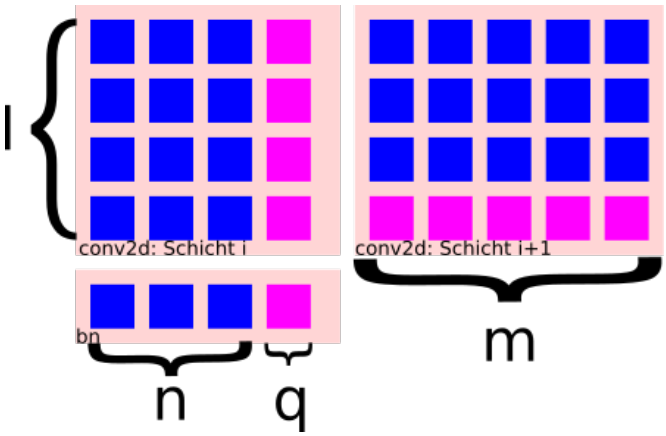

Abbildung 2.10: Übersicht über die zusätzlichen Kanäle

Für den Layer $j+1$ sind es entsprechend $q \cdot m$ zusätzliche Kernel. Die Gewichtstensoren nach dem Anwenden des Net2Net-Operators werden mit $\mathbf{U}^j$ und $\mathbf{U}^{j+1}$ bezeichnet und sollen die Dimensionalität von $\mathbf{U}^j : (n+q) \times l \times d(h_{(j,1)}) \times d(h_{(j,2)})$ und $\mathbf{U}^{j+1} : m \times (n+q) \times d(h_{(j+1,1)}) \times d(h_{(j+1,2)})$ haben. Der Net2Net-Operator wird angewendet, indem zunächst eine Mapping-Funktion g definiert wird, die für eine zufällige Belegung der zusätzlichen Kernels sorgt:

$$g(j) = \begin{cases} j & , \text{ falls } j \leq n \\ k & , \text{ falls } j > n : \ k \text{ zufälliges Sample von } \{1, 2, \ldots, n\} \end{cases} \tag{2.4}$$

Mit Hilfe dieser Mapping-Funktion werden nun die neuen Gewichtstensoren in-

itialisiert:

$$\mathbf{U}_j(e, f, h_{j,1}, h_{j,2}) = \mathbf{W}_j(g(e), f, h_{j,1}, h_{j,2})$$
$$\mathbf{U}_{j+1}(e, f, h_{j+1,1}, h_{j+1,2}) = \frac{1}{|\{x|g(x) = g(a)\}|}\mathbf{W}_{j+1}(e, g(f), h_{j+1,1}, h_{j+1,2})$$

Die Funktion $g(j)$ wird dabei für jede neu hinzugekommene Schicht nur einmal ausgewertet, sodass gesamte Reihen statt einzelner Kernel kopiert werden. Sollte sich zwischen dem j-ten und $(j+1)$-Layer eine Batchnormalisierungsschicht befinden, so werden die Parameter dieser Schicht ebenfalls kopiert.

Um nicht mehrere exakt gleiche Kernelreihen zu haben kann außerdem noch ein Noiseanteil auf alle Gewichte addiert werden. Dies ist vor allem für den Fall wichtig, wenn der Trainingsalgorithmus keine Form der Randomisierung hat, das heißt die gleichen Gewichtstensoren werden ermutigt, unterschiedliche Funktionen zu erlernen. Somit sind die vom ursprünglichen und neuen Netz gelernten Funktionen ähnlich aber nicht gleich.

Tieferes Netz

Der Operator für ein tieferes Netz ersetzt die Operation der j-ten Schicht $\mathbf{v}_{i,j} = \mathrm{BN}_{\gamma,\beta}(\mathbf{v}_{i,j} * \mathbf{W}_j)$ durch die Operation von zwei Layern

$$\mathbf{v}_{i,j} = \mathrm{BN}_{\gamma',\beta'}(\mathrm{BN}_{\gamma,\beta}(\mathbf{v}_{i,j} * t(W_j)) * t(U_j)) \tag{2.5}$$

$\mathbf{U}$ wird als Identitätsmatrix initialisiert. Da zwischen den beiden Layern eine Batchnormalisierung genutzt wird, müssen die Parameter der Batchnormalisierung γ' und β' so gewählt werden, dass sie die gelernte Funktion des Netzes nicht verändern.

Diskussion der Methode

Die beiden Net2Net-Operatoren schaffen die Möglichkeit, Familien von Netzarchitekturen zu erforschen ohne jedes Mal von neuem zu lernen. Mit Hilfe der beiden Operatoren lässt sich die Komplexität des Netzes erhöhen ohne die gelernte bisherige Funktion zu vernachlässigen.

2.6 Automatische Architektursuche

Neben dem im letzten Kapitel ausführlich erläuterten Ansatz des Strukturlernens gibt es noch einige andere aktuelle Ansätze, die automatisch nach einer besseren Architektur für einen Datensatz suchen. Einige dieser Ansätze werden hier beleuchtet und es wird gezeigt, wieso das im letzten Kapitel erläuterte Verfahren im praktischen Teil weiter verwendet wird.

Beim Versuch die Hyperparameter eines Netzes sinnvoll automatisch zu wählen, entsteht ein sehr großer Suchraum. Dieser Suchraum lässt sich mit viel Aufwand absuchen [MAL+19]. Es entsteht ein Optimierungsproblem mit mehreren zu optimierenden Variablen bei welchem eine Pareto-Front gesucht wird [MAL+19]. Das Ergebnis schafft eine Verbesserung der Accuracy gegenüber bekannten Architekturen, dabei summiert sich allerdings die Trainingszeit mit 20 NVIDIA V100 Grafikkarten für Imagenet auf 2,5 Tage[MAL+19]. Eine weitere Methode den Suchraum zu durchsuchen sind genetisch inspirierte Suchalgorithmen [SXZ+20]. Dabei wird initial eine Population von Netzen gebildet [SXZ+20]. Nach einem Trainingsdurchgang werden diese nach ihrer Fitness (Klassifikationsleistung) selektiert [SXZ+20]. Im weiteren Verlauf werden jeweils zwei dieser Netze gepaart und es entsteht eine neue Generation an Netzen [SXZ+20]. Allerdings ist hier die Trainingszeit in einem Rahmen von 35 GPUs für einen Tag [SXZ+20]. Dann ist die Architektursuche allerdings komplett automatisiert und erreicht eine Accuracy von 96.78 % für Cifar 10 und 79.77 % für Cifar 100 [SXZ+20]. [4]

Das Ziel von einigen Veröffentlichungen im Themenbereich der automatischen Architektursuche ist es, diese lange Trainingszeit zu reduzieren.

Eine Möglichkeit der Reduzierung bietet sich durch Ausnutzung von domainspezifischen Eigenschaften der zu klassifizierenden Bilder. Eine Möglichkeit einer domainspezifischen Eigenschaft, die genutzt werden kann, ist, wenn die Bilder nicht klassisch mit einer Kamera, sondern mit anderen Geräten aufgenommen wurden. Diese veränderte Aufnahmeart kann dafür sorgen, dass sich der Suchraum massiv einschränken lässt und sich damit die Architektursuche beschleunigt. Als Beispiel kann hier eine Radaranlage zur Aufnahme von Bilder dienen [DZZZ20].

Eine weitere Möglichkeit die Trainingszeit zu minimieren ist es, den Suchraum deutlich zu verkleinern und die Anzahl an Durchläufen zu minimieren. Der Nachteil ist dann allerdings, dass die Wahrscheinlichkeit, ein Netz in einem globalen

[4] Um diese Zahl einordnen zu können: die besten zehn Accuracy-Werte liegen für Cifar 10 bei 96.62 % bis 99.37 % und für Cifar 100 bei 82,35 % bis 93,51 %. Entsprechende Veröffentlichungen sind unter `https://benchmarks.ai/` zu finden

Optimum zu finden bezüglich des Suchraumes klein ist. Eine Methode die dies nutzt, wird im nächsten Unterkapitel vorgestellt.

2.7 Schnelles Ressourcen-beschränktes Strukturlernen tiefer Netzwerke

Im Gegensatz zu den Kapiteln 2.4 und 2.5, in denen jeweils eine Möglichkeit, ein CNN kleiner sowie größer zu machen vorgestellt wurden, geht es jetzt darum, dies zu kombinieren. Die Quelle für diese Kapitel ist, soweit nicht anders gekennzeichnet, das Paper, welches die Methode vorgestellt hat.
Die manuelle Wahl von Hyperparametern, die bestimmen wie groß und komplex ein neuronales Netz ist, braucht Erfahrung und Kunstfertigkeit. Sind die Hyperparameter falsch gewählt, so müssen diese angepasst und das Netz erneut trainiert werden. Mit Hilfe der hier vorgestellten Methode wird die Suche nach der besten Architektur automatisiert. Dies geschieht mit Hilfe von iterativen Verkleinern und Vergrößern des Netzes. Diese Methode hat drei Vorteile:

1. Es ist auf große Netze und große Datensätze skalierbar
2. Es kann die Struktur in Bezug auf eine bestimmte Nebenbedingung (zum Beispiel Modellgröße, Anzahl an Parametern) optimieren
3. Es kann eine Struktur lernen, die die Performance erhöht

Das Ziel der Methode ist es, automatisch die beste Architektur für ein Netz zu finden. Dies umfasst die Breiten der Eingangs- und Ausgangskanäle, Größe der Kernel, die Anzahl der Schichten und die Konnektivität dieser Schichten. Im Rahmen dieser Methode wird dies auf die Breite der Ausgangskanäle eingeschränkt. Die Methode kann auf die anderen Größen erweitert werden. Allerdings ist die Einschränkung auf die Breite der Ausgangskanäle sowohl effektiv als auch simpel. Die Breite der Ausgangskanäle für alle J Schichten wird mit $\mathcal{C}_{1:J}$ bezeichnet.
Der Anfangspunkt dieser Methode ist ein Netz $\mathcal{W}^1$ mit einer initialen Breite der Ausgangskanäle sowie fixen Filtergrößen. Die Nebenbedingung wird mit der Funktion $\mathcal{F}$ bezeichnet. Sie optimiert entweder die Modellgröße oder die Anzahl an Flops per Inferenz. Die Methode optimiert formal gesehen also folgendes:

$$\mathcal{W}^* = \underset{\mathcal{F}(\mathcal{C}_{1:J}) \leq \zeta}{\arg\min} \min_{\mathcal{W}} l(f(\mathbf{x_i}, \mathcal{W}), y_i) \tag{2.6}$$

Das Vergrößern des Netzes basiert auf einer Lösung für die Gleichung 2.6: dem Breitenmultiplikator ω. Sei $\omega \cdot O_{1:M} = \{\lfloor \omega O_1 \rfloor, \lfloor \omega O_2 \rfloor, \ldots, \lfloor \omega O_M \rfloor\}, \omega > 0$. Gilt $\omega > 1$, so wird das Netz vergrößert. Bei $\omega < 1$ wird das Netz verkleinert. Um die Gleichung 2.6 zu lösen, finde nun das größte ω, so dass $\mathcal{F}(\omega \cdot O_{1:M}) \leq \zeta$ gilt.
Dieser Ansatz sorgt für eine mögliche Verkleinerung und Vergrößerung des Netzes und er funktioniert gut bei einem guten initialen Netz. Ist das initialen Netz aber nicht von so guter Qualität, so hat dieser Ansatz Probleme. Grund hierfür ist wahrscheinlich ein lokales Minimum, aus welchem die Optimierungsfunktion nicht mehr herausfindet, um ein besseres lokales oder globales Minimum zu finden.
Dieser Nachteil wird durch eine Veränderung der Verlust-Funktion aufgehoben. Es wird ein Regularisierer $\mathcal{G}$ dazu addiert, welcher misst, wie groß der Anteil eines Netzbestandteiles an $\mathcal{F}(\mathcal{C}_{1:J})$ ist, und der es damit direkt optimieren kann. Dann ist

$$W^* = \underset{\mathcal{F}(\mathcal{C}_{1:J}) \leq \zeta}{\arg\min} \min_{\mathcal{W}} l(f(\mathbf{x_i}, \mathcal{W}), y_i) + \lambda \mathcal{G}(\mathcal{W}) \tag{2.7}$$

Dieser Ansatz kann die relative Größe einer Schicht ändern, hat aber den Nachteil das häufiger die zu optimierende Nebenbedingung nicht optimal maximiert wird. Die beiden Ansätze lassen sich kombinieren. Algorithmus 2.2 beschreibt den Algorithmus der bei der Kombination entsteht mit Pseudocode.

1: Trainiere das Netz um $\mathcal{W}^* = \underset{\mathcal{W}}{argmin}\, l(f(\mathbf{x_i}, \mathcal{W}, y_i) + \lambda \mathcal{G}(\mathcal{W}))$ zu finden
2: Finde die neue Breite $\mathcal{C}'_{1:J}$, die durch 1. errechnet wurde
3: Finde das größte ω, so dass $\mathcal{F}(\omega \cdot \mathcal{C}_{1:J}) \leq \zeta$ gilt
4: Wiederhole ab 1. so häufig wie gewünscht mit $\mathcal{C}_{1:J} = \mathcal{C}'_{1:J}$
Ausgabe: $\omega \cdot \mathcal{C}_{1:J}$

Algorithmus 2.2: MorphNet Algorithmus

Dieser Algorithmus kann so oft durchlaufen werden bis entweder die Performance des Netzes gut genug ist, oder bis die letzten Durchläufe keine Veränderungen mehr hervorgebracht haben.

2.7.1 Definition der Nebenbedingung

Die Nebenbedingung $\mathcal{F}$ lässt sich für verschiedene zu optimierende Zielgrößen definieren. Eine einfache Nebenbedingungen, die Modellgröße wird hier beispielhaft erläutert. Die Größe dieser Nebenbedingung wird vor allem durch Schichten mit Matrixmultiplikation dominiert. Die Modellgröße ergibt sich durch die Größe der Tensoren der einzelnen Schichten. Da die Größe der Tensoren der einzelnen

Schichten abhängig von der Anzahl der Eingangs- und Ausgangskänäle sowie der Filtergröße und nicht von der Position im Netzwerk ist, lässt sich $\mathcal{F}(\mathcal{C}_{1:J})$ auf die einzelnen Schichten zurückführen. Es gilt:

$$\mathcal{F}(\mathcal{C}_{1:J}) = \sum_{j=1}^{J} \mathcal{F}(j) \tag{2.8}$$

Für den Breitenmultiplikator ω gilt: $\mathcal{F}(\omega \cdot \mathcal{C}_{1:J} = \sum_{j=1}^{J} \omega \cdot \mathcal{F}(j)$
Die Abhängigkeit von der Größe des jeweiligen Tensors ergibt für

$$\mathcal{F}(j) = c_j \cdot k_j \cdot d(h_{j,1}) \cdot d(h_{j,2}) \tag{2.9}$$

Da durch die Anwendung des Regularisierers einzelne Kanäle auf Null gesetzt werden und ein Netz ohne diesen Kanal möglich wäre, sollen diese Kanäle in dieser Berechnung ausgelassen werden. Daher wird die Formel um Aktivierungsfunktionen $A_{k_l,j}$ und $B_{c_l,j}$ ergänzt die mit einer Eins angeben, dass der zugehörige Kanal nicht null ist. Eine Null als Ergebnis der Aktivierungsfunktion ergibt sich, wenn der entsprechende Kanal komplett auf Null gesetzt wurde. Dadurch lassen sich c_j und k_j aus Formel 2.9 ersetzen:

$$\mathcal{F}(j) = \left(\sum_{k=1}^{k_l} A_{k,j}\right) \cdot \left(\sum_{c=1}^{c_l} B_{c,j}\right) \cdot d(h_{j,1}) \cdot d(h_{j,2}) \tag{2.10}$$

2.7.2 Regularsierer

Beim Verkleinern des Netzes soll die Verlustfunktion l des CNN mit der Nebenbedingung $\mathcal{F}(\mathcal{C}_{1:J}) \leq \zeta$ minimiert werden. Bei der Wahl des Regularisierers muss bedacht werden, dass der Regularisierer und seine Ableitung kontinuierlich definiert sein müssen, da die Parameter im Netz durch ein Gradientenabstiegsverfahren gelernt werden. Zusätzlich kann eine Nebenbedingung nicht direkt durch ein Gradientenabstiegsverfahren gelernt werden. Daher wird $\mathcal{F}$ in veränderter Form als Regulariser gewählt. Die Veränderung umfasst das Hinzufügen von γ, die ähnlich einer Batchnormalisierung genutzt werden:

$$\mathcal{G}(j) = \left(\sum_{k=1}^{k_l-1} A_{k_l,j} \sum_{c=1}^{c_l-1} |\gamma_{c,j}|\right) \cdot \left(\sum_{k=1}^{k_l-1} |\gamma_{k,j}| \sum_{c=1}^{c_l-1} B_{c,j}\right) \cdot d(h_{j,1}) \cdot d(h_{j,2}) \tag{2.11}$$

Mit dieser Funktion lässt sich mittels Gradientenabstieg lernen, obwohl Teile des Regularisieres nicht komplett kontinuierlich sind. γ muss dabei kontinuierlich sein.

Werden die γ für einen Kanal auf Null gesetzt durch das Lernen, so ist der dazugehörige Kanal aus der Berechnung wie gewünscht ausgeschlossen. Für jeden Ein- und Ausgangskanal einer Schicht wird ein γ in den Vorwärts-Durchgang eingebaut. Diese Parameter funktionieren dann analog zu den γ aus der Batchnormalisierung, da sie kontrollieren, welcher Prozentsatz eines Kanals weitergeleitet wird.
Aus dem Regularisierer einer Schicht lässt sich mittels Addition die Regularisierung des kompletten Netzes berechnen.

$$\mathcal{G}(\mathcal{W}) = \sum_{j=1}^{J} \mathcal{G}(j) \tag{2.12}$$

Um die Wichtigkeit vom besseren Training des Netzes und der Regularisierung von Parametern treffen zu können wird ein Parameter λ eingeführt. So entsteht die Verlust-Funktion

$$\mathcal{W}^* = \underset{\mathcal{W}}{argmin}\ \ l(f(\mathbf{x}_i, \mathcal{W}), y_i) + \lambda \mathcal{G}(\mathcal{W}) \tag{2.13}$$

Dieser Regularisierer funktioniert nicht für Netze, die Kurzschlussverbindungen besitzen. Hier wird, wie beim Beschneiden des Netzes während des Trainings, ein Gruppen-Lasso verwendet. Dies stellt sicher, dass an Kurzschlussverbindungen nur so beschnitten werden kann, wie es für die Dimensionalität des Netzes zuträglich ist.

3 Überblick über die Arbeit

Im zweiten Teil dieser Arbeit werden die in Kapitel 2 theoretisch betrachteten Methoden praktisch auf einer GPU ausgeführt und evaluiert. Der Überblick über das experimentelle Setup wird in Kapitel 3.1 vorgestellt. In Kapitel 3.2 wird das Konzept des praktischen Teils der Arbeit erläutert.

3.1 Experimentelles Setup

3.1.1 Hardware

Die Hardware umfasst einen Server mit 4 GPUs. Von diesen 4 GPUs haben 2 GPUs jeweils den gleichen Typ:

- Geforce GTX 1080 Ti
- Geforce RTX 2080 Ti

Beide GPU-Typen arbeiten mit der CUDA Version 10.1.
Während der Vorbereitung auf diese Experimente hat sich gezeigt, dass Experimente mit einer Geforce GTX 1080 Ti mit den Experimenten der Geforce RTX 2080 Ti nicht vergleichbar sind. Weiterhin lässt sich durch das Verwenden von gemischt präzisen Zahlen nur auf der Geforce RTX 2080 ein Geschwindigkeitsvorteil beim Training feststellen. Aus diesen zwei Gründen wurden alle Experimente auf der Geforce RTX 2080 Ti ausgeführt.

3.1.2 Wahl des Frameworks

Es wird mit pytorch gearbeitet, da pytorch gegenüber anderen Frameworks eine grössere Flexibiltät erlaubt. Ausserdem ist eine fast vollständige Implementierung von PruneTrain in Pytorch geschrieben. Diese wird im nächsten Kapitel untersucht und soweit erweitert, dass es dem Stand im PruneTrain Paper entspricht.
Pytorch bietet mit cudnn und cuda im Hintergrund gute Möglichkeiten die Trainingszeiten einzelner Epochen zu messen und sie so mit einander zu vergleichen.

3.1.3 verwendete Netzarchitektur

Die PruneTrain Implementierung hat initial mehrere verschiedene Netzarchitekturen zur Auswahl:

- AlexNet
- ResNet 32/50
- vgg 8/11/13/16
- mobilenet

Diese Auswahl an Netzarchitekturen ist zu umfangreich, um alle diese Architekturen auf den vorgestellten Methoden zu evaluieren. Daher wird im Rahmen dieser Arbeit nur auf ResNet gearbeitet. Diese Entscheidung liegt daran, dass Resnets durch ihre Kurzschlussverbindungen gut mit sehr tiefen Netzstrukturen unmgehen können, ohne grosses Klassifikationsleistungsverluste dank Overfitting. Dies ist vorallem wichtig, wenn das Netz mit Hilfe des Operator für tieferes Netz noch tiefer gemacht werden soll. Die ResNet Struktur wird in der Implementierung so verändert, dass angeben werden kann wie tief das Netz sein soll. Das ResNet wird hier nicht mehr nur mit einer Zahl identifiziert sondern es wird angegeben, wieviele

- s: Anzahl an Phasen, die das ResNet hat
- $N = [n_1, \ldots, n_S]$: Anzahl von Blöcken pro Phase
- l: Anzahl von (Conv+Batch)-Layer pro Block
- $[k_1, \ldots, k_S]$: Breite der Schichten je Phase
- b: Boolean Parameter, der angibt ob die Blöcke im Netz die Bootleneck-Eigenschaft haben

das jeweilige ResNet hat. Diese Vorgehensweise hat den Vortei, dass für ein im Verlauf tieferes beziehungweise breitere Netz eine Vergleichsmöglichkeit besteht. Dies bedeutet, dass das Netz welches im Verlauf entsteht auch direkt erstellt werden kann.

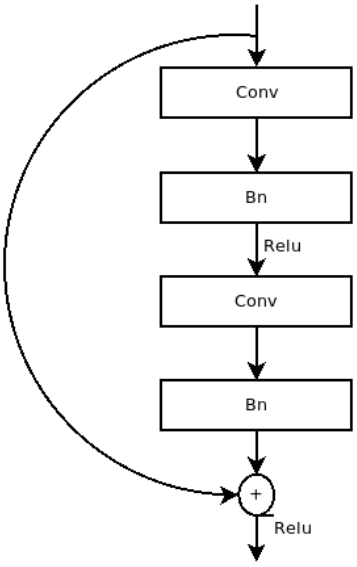

Abbildung 3.1: Basisblock

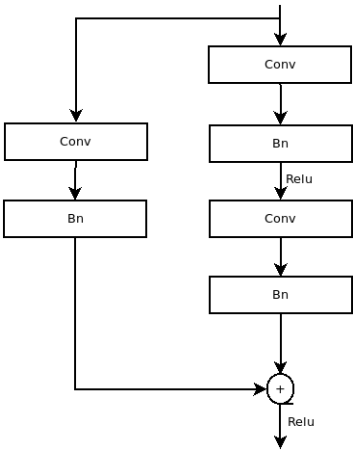

Abbildung 3.2: Übergangsblock

Abbildung 3.3: Grafische Darstellung Basis- und Übergangsblock

3.1.4 Baseline Netz

Um die Ergebnisse der Experimente in den folgenden Kapiteln einschätzen zu können wird ein ResNet, ohne Anpassungen um Trainingszeit zu sparen, trainiert. In Tabelle 3.1 ist die Struktur dieses Netze zu sehen. Das breite Baseline-Netz wird dabei für die Evaluierung des Beschneiden des Netzes verwendet. Das schmallere Baseline-Netz wird für die Evaluierung der Methoden, die das Netz breiter machen verwendet.

Das Netz hat drei Phasen ($s = 3$), wobei jeder der Phasen 5 Blöcke hat ($N = [5, 5, 5]$). Pro Basisblock sind zwei (Conv+Batch)-Schichten vorhanden ($l = 2$). Bei einem Übergangsblock, der als erster Block in einer neuen Phase bei einer Vergrösserung der Bereit beim Phasenübergang genutzt wird ist eine (Conv+Batch)-Schicht mehr vorhanden. Eine grafische Darstellung der Blöcke ist in Abbildung 3.3 zu sehen.

Evaluierung des breiteren Baseline-Netzes

Das Training wird über 180 Epochen durchgeführt. Es werden 5 Experimente durchgeführt. Dabei ergibt sich der in Abbildung 3.4a gezeigte Verlauf der Validierungs-Accuracy für Experiment vier. Bei diesem Training wurde über die gesamten 180 Epochen mit einer Lernrate von 0.1 trainiert. Mit einem Ergebnis von durchschnittlich 81.11 % über fünf Experimente ist diese Ergebnis leider nicht

Phase	Schicht/Block	breites Baseline-Netz		schmalles Baseline-Netz	
		#Eingangs-	#Ausgangs-kanäle	#Eingangs-	#Ausgangs-kanäle
	Conv 1 + Bn 1	3	16	3	8
1	Basisblock	16	16	8	8
	Basisblock	16	16	8	8
	Basisblock	16	16	8	8
	Basisblock	16	16	8	8
	Basisblock	16	16	8	8
2	Übergangsblock	16	32	8	16
	Basisblock	32	32	16	16
	Basisblock	32	32	16	16
	BasisBlock	32	32	16	16
	BasisBlock	32	32	16	16
3	Übergangsblock	32	64	16	32
	Basisblock	64	64	32	32
	Basisblock	64	64	32	32
	Basisblock	64	64	32	32
	Basisblock	64	64	32	32
	Linear	64	10	32	10

Tabelle 3.1: Struktur des Netzes

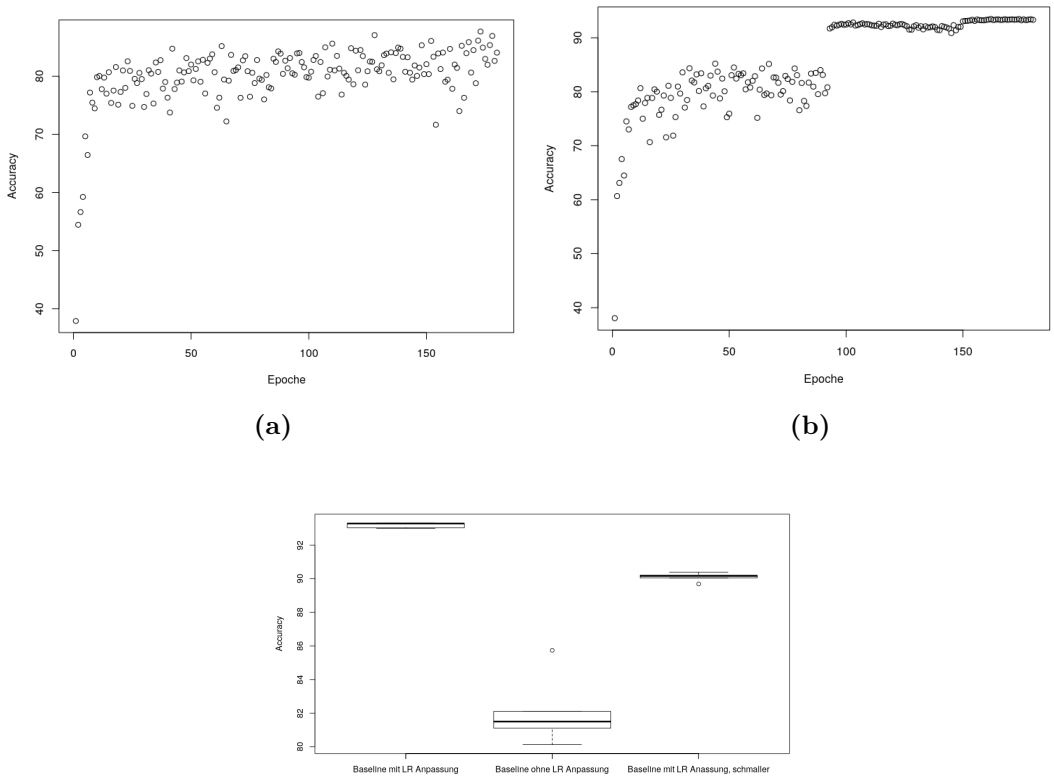

(a) **(b)**

(c)

Abbildung 3.4: Vergleich zwischen (a) Baseline-Netz ohne Anpassung der Lernrate und (b) Baseline-Netz mit Anpassung der Lernrate in Epoche 93 und 150. (c) Boxplot der Accuracys

zufriedenstellend.

Eine Verkleinerung der Lernrate kann dieses Ergebnis verbessern [GBC16]. In Abbildung 3.4b wird dargestellt, wie sich der Verlauf ändert durch eine Anpassung der Lernrate bei Epoche 93 und 150. In diesen beiden Epochen wird die Lernrate jeweils auf ein Zehntel verkleinert.

In Abbildung 3.4c ist ein Boxplot dargestellt, der die Accuracy von jeweils fünf Experimenten mit oder ohne Anpassung der Lernrate vergleicht. Es ergibt sich eine deutliche Verbesserung der Accuracy des Baseline-Netzes von 81.24 % auf 91.89 % durch diese Anpassung. Hier wurden die Epochen, zu denen die Lernrate verkleinert wurde manuell ausgesucht.

Ein weiteres Vergleichskriterium neben der Accuracy sind die durchschnittlichen Trainingszeiten pro Epoche. Für jedes Experiment wird die durchschnittliche Dauer einer Trainingsepoche mittel des arithmetiscen Mittels berechnet. Die

Durchschnittswerte über alle 180 Epoche sind für die zehn Baseline Experimente sind in Tabelle 3.2 aufgelistet. Die Durchschnittswerte liegen sehr nah beeinander, der Unterschied zwischen dem grössten und dem kleinsten Durchschnittswert liegt bei 0,28. Damit ergeben sich zwischen den zehn Experimenten keine signifikante Unterschiede. Es wird daher mit Experiment vier eines der Experimente mit Anpassung der Lernrate ausgesucht um für die folgenden Experimente/ Kapitel als Vergleich zu dienen.

	Experimente ohne Anpassung der Lernrate					Experimente mit Anpassung der Lernrate				
	1	2	3	4	5	1	2	3	4	5
μ	19,49	19,53	19,50	19,48	19,84	19,57	19,56	19,53	19.53	19.62

Tabelle 3.2: Tabelle für Durchschnittswerte und Standardabweichungen der Trainingszeiten der Experimente

Evaluierung des schmalleren Baseline-Netzes

schmalles Netz ohne LR-Anpassung

Das schmallere Baseline-Netz wird verwendet, um für MorphNet und Net2Net eine schmalle Variante zu haben. Der Grund hierfür ist, dass bei einer durchschnittlichen Accuracy von 93,19 % des breiten Baseline-Netzes nicht mehr viel Raum für Verbesserungen bleibt. In Abbildung 3.4c sind die Experimente für das breite und schmalle Baseline-Netz mit der Anpassung der Lernrate gegenüber gestellt. Der Unterschied vom breiten zum schmallen Netz ist ein Accuracy-Verlust von 3,1 %.
In Abbildung 3.5a ist abgebildet, wie sich die Accuracy für das schmallere Netz verhält, bei der gleichen Anpassung der Lernrate wie beim breiteren Baseline-Netzen. Der Unterschied in der Accuracy zwischen dem schmallen und breiten Baseline-Netz ist in Abbildung 3.5b abgebildet.

3.2 Konzept

In den nachfolgenden Kapiteln wird ein Konzept erarbeitet, wie MorphNet mit einer Kombination aus PruneTrain und Net2Net verglichen werden kann. MorphNet ist eine Technik, bei der die Struktur des Netzes durch Wiederholtes Verbreitern des Netzes und Verkleinern des Netzes mittels eines Regularisierers gelernt wird. PruneTrain beschneidet das Netz so, dass unwichtige Gewichte auf Null

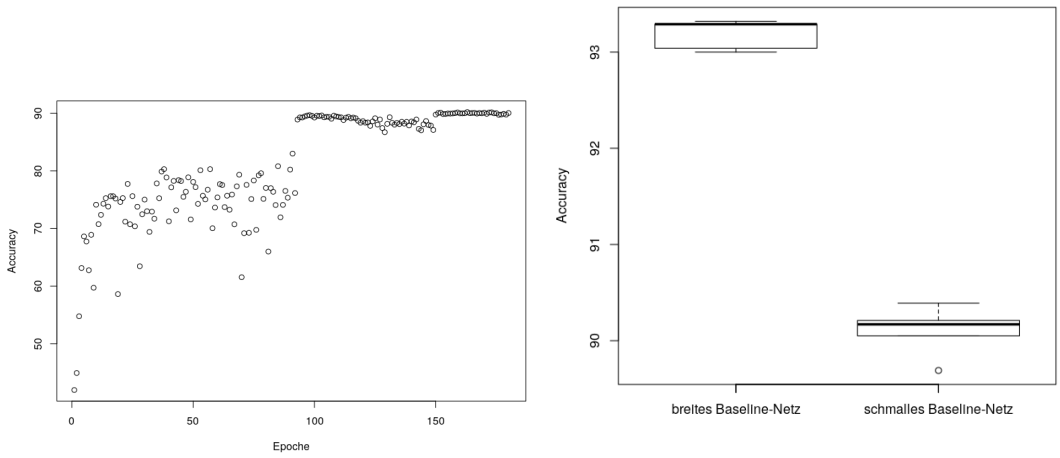

(a) **(b)**

Abbildung 3.5

gesetzt werden mit dem Ziel ganze Kanäle auf Null zu setzen um diese zu Entfernen. Mit der Entfernung von Kanälen und falls alle Kanäle einer Schicht auf Null gesetzt wurde auch ganzen Schichten, soll Trainingszeit gespart werden bei möglichst geringem Accuracy Verlust. Die Evaluierung von MorphNet wird in Kapitel 4 durchgeführt. In Kapitel 5 wird das PruneTrain Verfahren evaluiert. Anschliessend wird in Kapitel 6 das Net2Net Verfahren evaluiert. In Kapitel **??** wird erarbeitet, wie die Kombination aus PruneTrain und Net2Net gestaltet werden könnte. Abschliessend wird in Kapitel 7 das Ergebnis der Arbeit zusammengefasst und ein Ausblick auf das weitere mögliche Vorgehen gegeben.

4 Untersuchung von MorphNet

Die in Kapitel 2.7 erläuterte Methode zum "schnellen Ressourcen beschränkten Strukturlernen" (MorphNet) wird in diesem Kapitel evaluiert. In Algorithmus 2.2 wurde das Vorgehen von MorphNet mittels Pseudocode dargestellt. Im ersten Schritt zur Evaluierung werden die einzelnen Schritte in diesem Algorithmus evaluiert. Im zweiten Schritt wird überprüft, wie gut der Algorithmus auf dem Datensatz Cifar10 trainiert auf einem ResNet abschneidet. Da als Framework Pytorch verwendet wird kann die ursprängliche Implementation hier nicht verwendet werden. Es erscheint nicht sehr sinnvoll zwei Verfahren zu vergleichen, die auf unterschiedlichen Frameworks aufbauen. Stattdessen wird die im Rahmen einer anderen Veröffentlichung erstellte Implementierung vom MorphNet benutzt[1] [CDZM20]. Unterschiede in der Implementierung sollten hier theoretisch nicht vorliegen, da der originale Programmcode von MorphNet verfügbar ist[2].

4.1 Evaluierung der einzelnen Schritte von MorphNet

Im ersten Schritt von MorphNet wird das Netz trainiert, so dass

$$\mathcal{W}^* = \underset{\mathcal{W}}{argmin}\ l(f(\mathbf{x_i}, \mathcal{W}, y_i) + \lambda \mathcal{G}(\mathcal{W})) \tag{4.1}$$

minimiert wird. Der Regularisierer $\mathcal{G}$ ist in dieser Formel dafür zuständig, dass die gewählte Zielgröße minimiert wird. Die zwei möglichen Zielgrößen sind die Modellgröße und Anzahl an FLOPs. Für beide Zielgrößen gilt, dass die im Regularsierer verwendete Formel nur eine vereinfachte Form der Zielgrösse berechnet. Deshalb wird zunächst evaluiert, welchen Effekt der Regularisierer auf die Zielgröße hat. Dabei werden nur die ersten beiden Schritte des MorphNet-Algorithmus

[1] Die benutzte Implementierung ist auf Github zu finden: `https://github.com/cmu-enyac/LeGR/`

[2] Der original Programmcode ist ebenfalls auf Github zu finden: `https://github.com/google-research/morph-net`

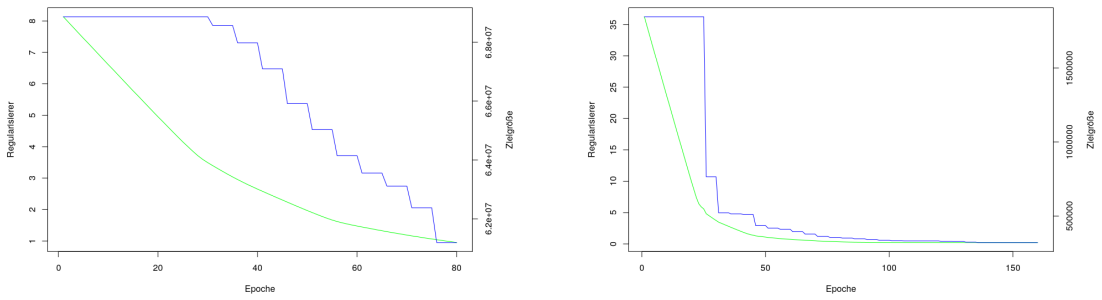

(a) **(b)**

Abbildung 4.1: Vergleich Zielgröße mit Wert des Regularisierers für (a) FLOPs (b) Modellgröße

durchgeführt.

In Abbildung 4.1a ist in Grün abgebildet, wie sich der Wert des Regularisieres für die Zielgrösse FLOPs während dem Training verändert. Die blaue Kurve in Abbildung 4.1a ist der tatsächliche Verlauf der Flops über die Trainingszeit. Die blaue Kurve wird in Schritten weniger, da das Netz nur alle fünf Epochen mittels der zweiten MorphNet-Schrittes beschnitten wird. Die verzögerte Reduzierung der Zielgröße liegt daran, dass erst mit einer gewissen Anzahl entfernbarer Gewichte tatsächlich eine Änderung an den FLOPs passiert. Für die Zielgröße Modellgröße ist der Verlauf der beiden Kurven in Abbildung 4.1b abgebildet. Für die Zielgröße Modellgröße muss λ größer sein um einen Effekt auf die Zielgröße zu haben. Es zeigt sich, dass $\mathcal{G}$ tatsächlich für eine minimierte Zielgröße sorgt.

Der Effekt von verschieden großen λ wird im nächsten Schritt untersucht. Zu diesen Zweck wird ein Netzwerk mit verschiedenen Werten für λ trainiert. Dabei wird das Netz jeweils für 180 Epochen trainiert und anschliessend wird das Netz beschnitten. Abhängig von der Größe von λ wird dem Regularisierer mehr oder weniger Gewicht gegeben. In Abbildung 4.2a ist zu sehen, wie sich der MorphNet Algorithmus bei verschiedenen λ für die Zielgröße FLOPs verhält. In Abbildung 4.2b ist abgebildet wie sich die Netzverkleinerungsraten verändern, bei der Zielgröße Modellgröße. In der Originalveröffentlichung wurde der Effekt von verschiedenen λ untersucht und für die Zielgröße FLOPs auch dargestellt. Dabei zeigte sich, dass mit verschiedenen Werten von λ eine Kurve gebildet werden konnte, die für das Verhältnis zwischen Flops per Inferenz und der Accuracy einen Zusammenhang findet: Je kleiner die Flops Anzahl ist, so geringer ist auch die Accuracy [GEN+18]. Wie in Abbildung 4.2a für die Zielgröße Flops zu sehen ist, ist dieser Zusammenhang für ein ResNet nicht zu finden. In Abbildung 4.2c

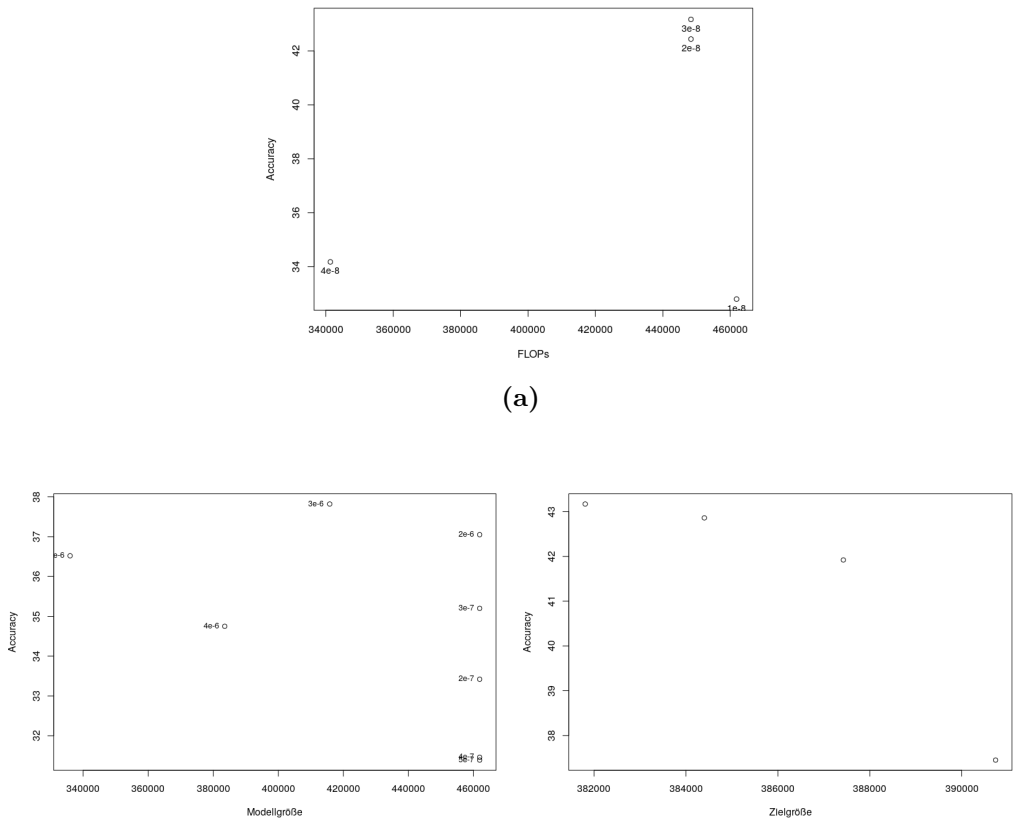

(a) **(b)** **(c)**

Abbildung 4.2: Effekt verschieden großer λ auf (a) FLOPs (b) Modellgröße. (c) Effekt verschiedener Experimente bei festem λ

ist abgebildet, wie sich die Zielgröße Flops im Zusammenhang mit der Accuracy verändert, bei einem festen $\lambda = 3 \cdot 10^{-8}$. Im Vergleich zeigt sich jetzt das in Abbildung 4.2b für mehrere verschiedene λ eine Accuracy Spanne von x % ergibt. Bei $\lambda = 3 \cdot 10^{-8}$ ergibt sich eine Spanne von x %. Damit zeigt sich, dass das Ergebnis nach einem Beschneidungsvorgang nicht stabil ist. Dies könnte an der generellen Instabilität des Trainings liegen (stark sich verändernde Accuracy-Werte) oder an strukturellen Unterschieden zum Inception Netz. Wie in Kapitel 2.2.2 geschrieben unterscheidet sich das ResNet vom Inception Netz durch das Fehlen von Kurzschlussverbindungen, das Anwenden meherere Filter im Inception Netz und der Tiefe vom Inception Netz. Ein weiterer Unterschied, der für das unterschiedliche Abschneiden verantwortlich sein. könnte ist die Verwendung von Cifar10 statt Imagenet.

Evaluierung der Laufzeit

Da sich aus dem Experiment für die verschiedenen λ kein Kandidat mittels einer

Heuristik aussuchen lässt findet die Evaluierung in nächsten Unterkapitel mit mehreren λ statt.

4.2 Evaluierung der Ergebnisse von MorphNet

Um zu evaluieren, wie gut MorphNet auf einem ResNet mit Cifar10 abschneidet wird für verschiedene Werte von λ der gesamte Algorithmus mehrfach ausgeführt. Die Grundlage bietet das schmalle Baseline-Netz.

Grafiken die zeigen, dass das alles hier nicht besser abschneidet als das breite Baseline-Netz.

Der Grund, wieso MorphNet hier nicht besser abschneidet kann zwei Gründe haben:

- Fehler in der Implementierung, der dafür sorgt, dass das Pruning an den Grenzen der Blöcke schwächer gewichtet ist als das Prunen innerhalb der Blöcke -> Abhilfe wie bei PruneTrain Lasso berechnen.
- das breite Baseline-Netz ist bereits die bestes Struktur die man sich wünschen kann. Besser wird es nur noch durch andere Lernrate oder tiefere Struktur

5 Evaluation des Beschneidens des Netzes

5.1 Evaluation bei gleichbleibender Batchgröße

Die Untersuchung von PruneTrain basiert auf einer bereits vorgefertigten Implementierung [ptI]. In dieser Implementierung ist alles bis auf die Anpassung der Batchgröße an das kleiner werdende Netz enthalten. Das Ergebnis der Ausführung von PruneTrain auf der Hardware wird mit den Ergebnissen aus der Veröffentlichung verglichen [LCZ+19]. Ziel der Experimente ist es zu evaluieren, wie eine Änderung der verschiedenen Hyperparameter die Trainingszeit und die Accuracy beeinflusst. Im Gegensatz zur Veröffentlichung von PruneTrain wird hier statt auf mehreren GPUs nur auf einer GPU gerechnet. So kann evaluiert werden, wieviel der PruneTrain Effekte auf das Setup mit mehreren GPUs in der Veröffentlichung zurückzuführen sind.
Bei der Evaluierung der Einflüsse werden die veränderbaren Hyperparameter von PruneTrain einzeln verändert, um den Einfluss der einzelnen Veränderungen zu untersuchen. Die veränderbaren Hyperparameter sind:

- Lasso-Ratio $0,2$
- Rekonfigurationsinterval 5
- Grenzwert $0,0001$
- Lernrate $0,1$

Hinter den veränderbaren Hyperparameter steht jeweils der Wert, den der Hyperparameter hat, wenn er im aktuellen Experiment nicht verändert wird. Betrachte eine feste Batchgröße von 256 über 180 Epochen und vergleiche diese mit dem Baseline-Netzes aus Kapitel 3.1.4. Für jede Gruppe von Experimenten werden 5 Experimente durchgeführt.

	Lasso 0,05	Lasso 0,1	Lasso 0,15	Lasso 0,2	Lasso 0,25
Baseline	$6,9 \cdot 10^{-6}$	$< 2,2 \cdot 10^{-16}$	$< 2,2 \cdot 10^{-16}$	$2,9 \cdot 10^{-5}$	$4,9 \cdot 10^{-5}$
Lasso 0,05	X	0,0299	0,0199	0,0002	$5,6 \cdot 10^{-5}$
Lasso 0,1	X	X	0,0025	0,0035	0,0016
Lasso 0,15	X	X	X	0,0046	0,0019
Lasso 0,2	X	X	X	X	0,2540

Tabelle 5.1: p-Werte für den t-Tests zu den durchschnittlichen Trainingszeiten der Lasso-Ratio Experimente

Einfluss von verschiedenen Lasso-Ratio Werten auf das Netz

Die Lasso-Ratio gibt an, wie stark das Netz beschnitten werden soll. In diesen Experimenten wird die Lasso-Ratio von 0,05 bis 0,25 in 0,05er Schritten verändert. In Abbildung 5.1a ist zusehen, dass mit steigender Lasso-Ratio durchschnittlich weniger Trainingszeit gebraucht wird. Für die durchschnittliche Trainingszeit eines Experiments wird das arithmetische Mittel über alle Epochen angewandt. Die Experimente werden dann nach ihrer Zugehörigkeit einsortiert und als Boxplot in Abbildung 5.1a dargestellt. Trotz der nachlassenden Trainingszeit mit steigender Lasso-Ratio ist die Trainingszeit des Baseline-Netzes signifikant schneller. Dies ist durch den Overhead erklärbar, welcher durch das Beschneiden des Netzes entsteht. Um zu überprüfen, wie signifikante diese Unterschiede zwischen den Experimentengruppen hier sind werden paarweise t-Tests mit einem Signifikanzniveau $\alpha = 0,05$ durchgeführt. Die resultierenden p-Werte sind in Tabelle 5.1 zu sehen.

Da bis auf den t-Test zwischen den Lasso Werten 0,2 und 0,25 alle p-Werte kleiner dem Signifikanzniveau sind ist ein Fehler 1.Art sehr unwahrscheinlich. Daher lässt sich für die übrigen Wertepaare die Aussage treffen, dass sie einen statistisch signifikanten Unterschied der Mittelwerte haben. Somit entsteht durch das Erhöhen der Lasso-Ratio ein signifikante Einsparung an Trainingzeit gegenüber einer kleineren Lasso-Ratio. Gegenüber den durchschnittlichen Trainingszeiten des Baseline-Netzes ist allerdings das Baseline in allen Fällen signifikante schneller.

In Abbildung 5.1b ist die Accuracy der verschiedenen Experimente abgebildet. Es fällt auf, dass das Baseline-Netz im Mittel etwas besser ausfällt als die Experimente mit dem Lasso-Ratio 0,05. In Tabelle 5.2 sind die Werte für den paarweisen t-Test zwischen den Accuracy der Experimentegruppen abgebildet. Das Signifikanzniveau beträgt $\alpha = 0,05$. In der Tabelle ist zu sehen, dass die rot hinterlegten p-Werte größer als das Signifikanzniveau sind. Somit ist für diese paarweisen Ac-

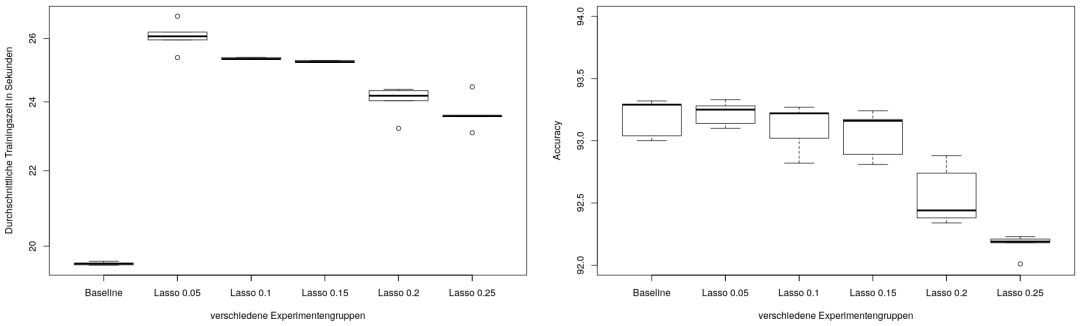

(a) **(b)**

Abbildung 5.1: Lasso-Ratio Experiment: (a) Boxplot der durchschnittlichen Trainingszeit (b) Boxplot der Accuracy

Tabelle 5.2: p-Werte für den t-Tests zu den Accuracy-Werten der Lasso-Ratio Experimente

	Lasso 0,05	Lasso 0,1	Lasso 0,15	Lasso 0,2	Lasso 0,25
Baseline	0,7068	0,4952	0,2586	0,0018	$8,6 \cdot 10^{-6}$
Lasso 0,05	X	0,2898	0,1341	0,0010	$1,0 \cdot 10^{-7}$
Lasso 0,1	X	X	0,6530	0,0041 ig	$7,5 \cdot 10^{-5}$
Lasso 0,15	X	X	X	0,0072	0,0001
Lasso 0,2	X	X	X	X	0,0182

curacy die Wahrscheinlichkeit für einen Fehler 1. Art zu groß für die Aussage, dass die Accuracy der Experimente einen unterschiedlichen Mittelwert haben. Es lässt sich jedoch erkennen, dass für jede Zeile die p-Werte kleiner werden, je größer die Lasso-Ratio wird. Somit lässt sich die begründete Aussage treffen, dass mit steigender Lasso-Ratio die Accuracy signifikant abnimmt. Die fehlende Signifikanz dieser Paare kann sowohl an der fehlenden statistischen Signifikanz liegen als auch an der kleinen Anzahl an Experimenten pro Gruppe. Da die hier getroffene Aussage allerdings ausreicht wird das Experiment nicht mit grösserer Anzahl wiederholt.

Experimente zum Rekonfigurationsintervall

Als nächste Größe wird der Einfluss des Rekonfigurationsintervalls überprüft. Die entsprechenden Grafiken sind in Abbildung 5.2 zu sehen. In Abbildung 5.2a sind für die verschiedenen Experimente die Trainingszeiten pro Epoche zu sehen. Dabei werden drei verschiedene Rekonfigurationsintervalle (2,5 und 10) verglichen. In Abbildung 5.2a lässt sich für die verschiedenen durchschnittlichen Trainingszei-

Tabelle 5.3: p-Werte für den t-Tests zu den durchschnittlichen Trainingszeiten der Rekonfigurationsinterval Experimente

	Rekonf 2	Rekonf 5	Rekonf 10
Baseline	$4,7 \cdot 10^{-7}$	$6,4 \cdot 10^{-5}$	0.0002
Rekonf 2	X	0.6034	0.9853
Rekonf 5	X	X	0.9859

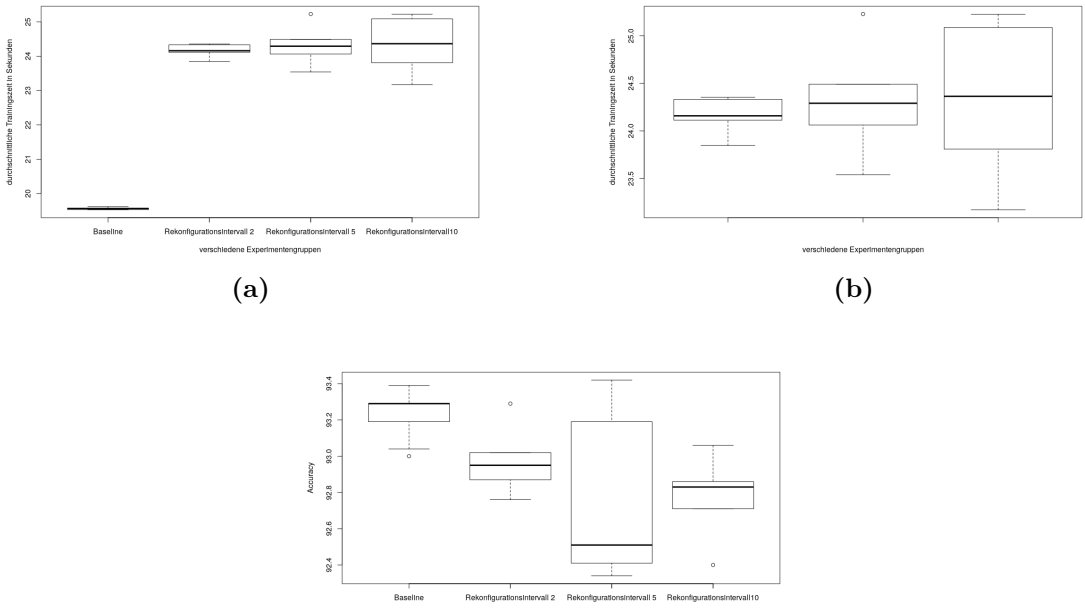

(a) **(b)**

(c)

Abbildung 5.2: Experimente zum Rekonfigurationsintervall: (a) Boxplot der durchschnittlichen Trainingszeit (b) Boxplot der durchschnittlichen Trainingszeit ohne Baseline-Netz (c) Boxplot der Accuracy

ten der Experimente zum Rekonfigurationsintervall kaum Unterschiede erkennen. Daher ist in Abbildung 5.2b ein Boxplot ohne die Baseline Werte abgebildet. Der Grund hierfür ist, dass sich die Zeitersparnis durch das vermehrte Beschneiden aufgrund einem kleinerem Rekonfigurationsintervall mit dem nötigen Overhead der häufigeren Rekonfiguration aufhebt.

In Tabelle 5.3 ist bestätigt, das zwischen den durchschnittlichen Trainingszeiten der Experimente kein signifikanter Unterschied ist. Dabei ist zu bedenken, dass die Experimentanzahl mit fünf relativ klein ist. Wichtiger als die hier eventuell minimale Einsparung von Trainingszeit ist die Auswirkung auf die Accuracy.

In Abbildung 5.2c ist zu sehen, wie sich die Accuracy bei diesen Experimenten verhält. Zu sehen ist, dass die Accuracy keine klare Tendenz hat. Dies zeigt sich

Tabelle 5.4: p-Werte für den t-Tests zu den Accuracys der Rekonfigurationsinterval Experimente

	Baseline	Rekonf 2	Rekonf 5	Rekonf 10
Baseline	X	0.0478	0.1111	0.0105
Rekonf 2	X	X	0.43	0.1824
Rekonf 5	X	X	X	0.9938
Rekonf 10	X	X	X	X

Tabelle 5.5: p-Werte für den t-Tests zu den Accuracys der durchschnittlichen Experimenten zur Lernrate

	Baseline	LR 0,2	LR 0,1	LR 0,05	LR 0,025
Baseline	X	0,0003	5,265*10^-5	0,0003	4,888*10^-6
LR 0,2	X	X	0,0001	0,0011	9,211*10^-7
LR 0,1	X	X	X	0,0332	0.0011
LR 0,05	X	X	X	X	0,9074
LR 0,025	X	X	X	X	X

auch in den t-Test in Tabelle 5.4. Hier ist die Anzahl an Experimenten wohl zu gering, um eine klare Aussage zu treffen. Da die Unterschiede hier aber so gering sind ist die Wahl des Rekonfigurationsintervall nicht so wichtig.

Experimente zur Lernrate

Vergleich mit Baseline und verschiedenen LR

Der Einfluss der Lernrate auf das Beschneiden des Netzes wird mit fünf verschiedenen Lernraten untersucht. Beginnend mit der Lernrate $0,2$ und für jede weitere der fünf Lernraten die Hälfte der vorherigen. Die durchschnittliche Trainingszeit in Sekunden für verschiedene Lernrate ist in Abbildung 5.4 zu sehen. Es ist deutlich zu sehen, dass mit sinkender Lernrate die Trainingszeit steigt. Das bedeutet, dass mit sinkender Lernrate weniger von Netz beschnitten wird, dies sorgt allerdings nicht zu einem verringerten Overhead. Der Overhead hängt bei diesem Verfahren von der Häufigkeit der Rekonfiguration ab.
In Tabelle 5.5 sind die p-Werte für die paarweisen t-Test zu sehen, die berechnen wie wahrscheinlich es ist, dass ein Fehler 1. Art auftritt. Da die p-Werte bis auf einen Wert unter dem Signifikanzniveau von $\alpha = 0,05$ ist die hier getroffene Aussage statistisch belegt.
In Abbildung 5.3b sind die Accuracy der verschiedenen Lernraten abgildet. Die Lernrate 0.1 schneidet hier am Besten ab. Dies kann darauf zurück geführt werden, dass bei einer größeren Lernrate weniger Minima in der Verlustfunktion

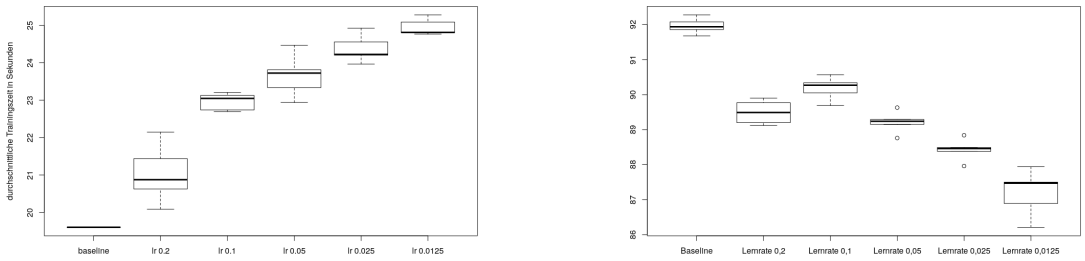

(a) **(b)**

Abbildung 5.3: Experimente zur Lernrate: (a) Boxplot der durchschnittlichen Trainingszeit (b) Boxplot der durchschnittlichen Trainingszeit ohne Baseline-Netz (c) Boxplot der Accuracys

Tabelle 5.6: p-Werte für den t-Tests zu den Accuracys der Experimente zu den Lernraten

	Baseline	LR 0,2	LR 0,1	LR 0,05	LR 0,025
Baseline	X	3,355*10^-5	0,0005	0,7253	0,004
LR 0,2	X	X	0,0003	4,83*10^-5	0,0005
LR 0,1	X	X	X	0,0006	0,8715
LR 0,05	X	X	X	X	0,0003
LR 0,025	X	X	X	X	X

gefunden werden können. Der Effekt bei wesentlich kleineren Lernraten ist, dass der Trainingsprozess zwar mit jedem Schritt in die Richtung des Minimums geht, dabei aber durch die kleine Lernrate das tatsächliche Minimum innerhalb der 180 Epochen nicht erreicht wird oder mit der kleinen Lernrate ein lokales Minimum nicht verlassen werden kann. In Tabelle 5.6 sind die p-Werte der paarweisen t-Tests zu sehen. Bis auf zwei Werte sind diese kleiner als das Signifikanzniveau $\alpha = 0,05$. Damit ist die Wahrscheinlichkeit für einen Fehler 1.Art bis auf diese zwei Werte kleiner als 5 %. Damit sind die hier getroffenen Aussagen statistisch belegt sind.

Experimente zum Grenzwert

Der Einfluss des gewählten Thresholds wird hier untersucht. In Abbildung 5.4a sind die durchschnittlichen Trainingszeiten abgebildet. Auch hier ist zu sehen, dass die durchschnittliche Trainingszeit durch die Anwendung des PruneTrain Algorithmus zunimmt.Unter einem bestimmten Threshold-Wert sind hier die durchschnittlichen Trainingszeiten nicht mehr unterscheidbar. In Tabelle 5.7 sind die

Tabelle 5.7: p-Werte für den t-Tests zu den durchschnittlichen Trainingszeiten der Experimente zum Threshold

	Baseline	Thres. 0,1	Thres. 0,01	Thres. 0,001	Thres. 0,0001
Baseline	X	0.0003	0.0002	1.778e-05	0.0002
Thres. 0,1	X	X	0.0577	0.0018	0.0479
Thres. 0,01	X	X	X	0.1209	0.9159
Thres. 0,001	X	X	X	X	0.1450
Thres. 0,0001	X	X	X	X	X

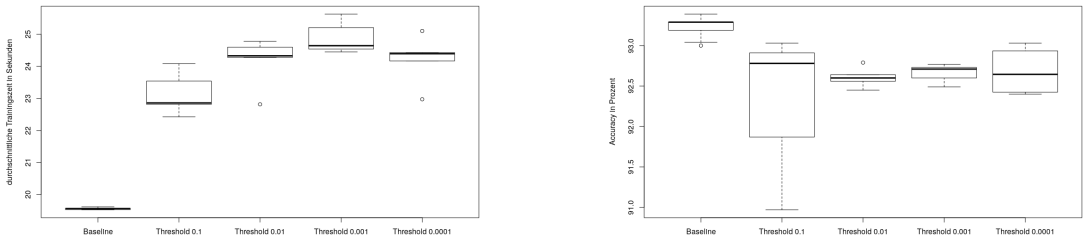

(a) **(b)**

Abbildung 5.4: Experimente zur Threshold: (a) Boxplot der durchschnittlichen Trainingszeit (b) Boxplot der durchschnittlichen Trainingszeit ohne Baseline-Netz (c) Boxplot der Accuracys

p-Werte des t-Tests abgebildet, der untersuchen soll wo ein statistisch signifikanter Unterschied zwischen den durchschnittlichen Trainingszeiten der Experimentengruppen herrscht. Die p-Werte stützen die Aussagen.

In Abbildung 5.4b ist die Accuracy zu sehen. Aus dieser Abbildung lässt sich keine Tendenz erkennen. Diese Aussage wird durch die p-Werte der paarweisen t-Tests in Tabelle 5.8 gestützt.

Tabelle 5.8: p-Werte für den t-Tests zu den Accuracys der Experimente zum Threshold

	Baseline	Thres. 0,01	Thres. 0,001	Thres. 0,0001	Thres. 0,00001
Baseline	X	0,1927	0,0002	0,0003	0,0360
Thres. 0,01	X	X	0,6799	0,6121	0,5968
Thres. 0,001	X	X	X	0,5096	0,6815
Thres. 0,0001	X	X	X	X	0,9076
Thres. 0,00001	X	X	X	X	X

Diskussion der Methode

Für die Evaluation des Beschneiden des Netzes werden in der Original-Veröffentlichung mehrere GPUs verwendet [LCZ+19]. Dies führt dazu, dass bereits in diesem Teil der Implementierung Trainingszeit durch verminderte Kommunikation zwischen den GPUs gespart wird. Da hier nur mit einer GPU evaluiert wird ergibt sich hier noch keine direkte Einsparung an Trainingszeit. Eine weitere Möglichkeit Trainingszeit zu sparen ergibt sich durch Erhöhen der Batchgröße bei kleiner werdendem Netz. Zu beachten ist hier, dass die Speicherauslastung gleich bleiben sollte und eine Vergleichbarkeit mit der Veröffentlichung zu gewährleisten. Diese Evaluierung wird in Kapitel 5.2 durchgeführt.

5.2 Experimente zur Anpassung der Batchgröße beim Beschneiden des Netzes

Die Anpassung der Batchgröße des Netzwerks in der Veröffentlichung arbeitet mit einer Grenze bis zu dieser der Speicher ausgelastet werden darf.
Die Berechnung der maximalen Batchgröße für eine gegegebene Speichergrösse und Netzarchitektur wird in Kapitel 5.2.1 beschrieben.

5.2.1 Berechnung der Batchgröße abhängig vom Speicherverbrauch

Da sich in Pytorch der freie Speicher nicht direkt auslesen lässt wird mit Hilfe von Experimenten, die auf der GPU durchgeführt werden gemessen wie sich die Speicherauslastung verhält. In Abbildung 5.5a ist zu sehen, wie sich die Speicherauslastung proportional zur Batchgröße verhält. Es ist gut zu erkennen, dass der Zusammenhang linear ist. Die Passgenauigkeit dieses Zusammenhangs kann mittels einer linearen Regression bestimmt werden. Daher wird mit der roten Gerade eine lineare Regression berechnet. Der maximale Abstand der gemessenen Punkte zur Gerade ist $0,19$ für Punkte, die unter der Gerade liegen sowie $0,67$ für Punkte die über der Gerade liegen. Zusammen mit der graphischen Übereinstimmung ergibt sich klar ein linearer Zusammenhang mit kleinen Abweichungen. Durch diesen linearen Zusammenhang reicht es ein Modell zu bilden, welches für einen Wert des Speicherverbrauchs abhängig von der Netzarchitektur berechnet, wie groß die Batchgröße maximal sein darf. Zu diesem Zweck wird ein Netz mit

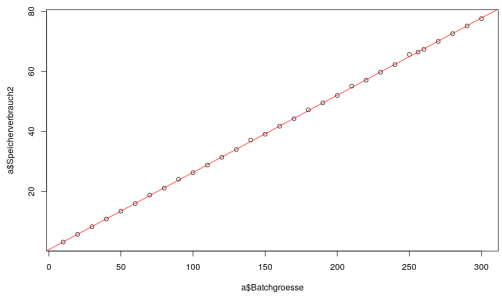

(a)

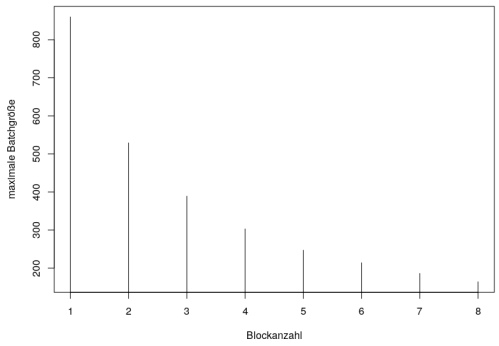

(b)

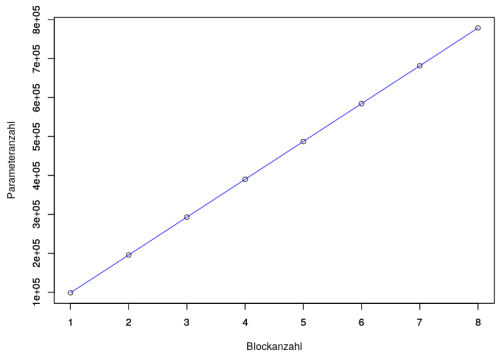

(c)

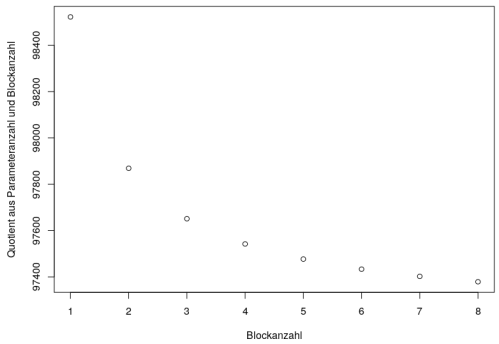

(d)

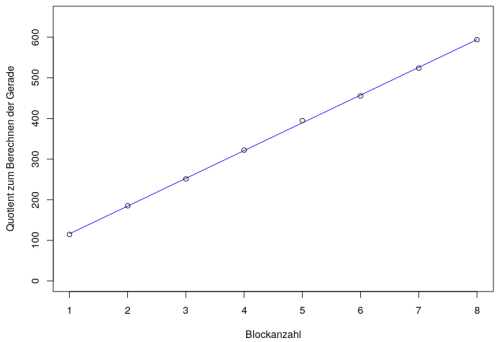

(e)

Abbildung 5.5: Darstellung des Berechnen der Geraden

drei Phasen betrachtet und ein Modell entwickelt mit dem sich die maximale Batchgröße berechnen lässt. Die maximale Batchgröße hängt ab von:

- der Blockanzahl
- der Phasenanzahl und
- der Anzahl an Schichten pro Block
- Breite der Schichten je Phase

In Abbildung 5.5b ist abgebildet, wie sich die Blockanzahl bei gleichbleibender Speicherauslastung auf die maximale Batchgröße auswirkt. Die Blockanzahl wirkt sich wie zu sehen ist nicht linear auf die maximale Batchgröße aus. Die maximale Blockanzahl hängt ab von der maximalen Speicherauslastung während einer Epoche. Dies ist abhängig von der Blockgröße, da aufgrund der Kurzschlussverbindungen die Ausgabe jedes Blocks zwischengespeichert werden muss. Betrachtet man hingegen den Zusammenhang zwischen Blockanzahl und Parameteranzahl, wie in Abbildung 5.5c abgebildet, so ergibt sich hier ein linearer Zusammenhang. In Abbildung 5.5d ist der Zusammenhang zwischen Blockanzahl und dem Quotienten aus Parameteranzahl und Blockanzahl zu sehen. Der Verlauf dieser Kurve ähnelt dem Verlauf von Abbildung 5.5b. In Abbildung 5.5e wird daher der Quotient aus diesen beiden Größen gegen die Blockanzahl abgebildet und eine Gerade mit linearer Regression berechnet.
Um die Wahrscheinlichkeit zu prüfen, dass in Abbildung 6.1 fälschlicher Weise ein linearer Zusammenhang angenommen wird, wird ein t-Test ausgeführt. Es ergibt sich die Alternativ- und Nullhypothese:

H_0 : Es besteht kein linearer Zusammenhang zwischen dem Quotienten G und der Anzahl von Blöcken

H_1 : Es besteht ein linearer Zusammenhang zwischen dem Quotienten G und der Anzahl von Blöcken

Mit einem Signifikanzniveau von $\alpha = 0,05$ und einem p-Wert von $p = 3,824 \cdot 10^{-12}$ ist die Nullhypothese abzulehnen, und die Alternativhypothese anzunehmen.
Mit Hilfe dieses linearen Zusammenhangs lässt sich bei gegebener Parameteranzahl (PA) und Blockanzahl (BA) die maximale Batchgröße (BG) berechnen:

$$BG = \frac{PA}{BA\,(68,25 \cdot BA + 47,85)} \tag{5.1}$$

Da einzelne Punkte einen maximalen Abstand von $d = 2,07$ zur Geraden wurde das Ergebnis durch Multiplikation mit $0,98$ ein Sicherheitsabstand eingeführt.

5.2.2 Evaluierung der Anpassung der Batchgröße an die Netzgröße

Da sich für ein gegebenes Netz die Speicherauslastung abhängig von der Batchgröße ein linearer Zusammenhang ergibt, kann die Batchgröße direkt angepasst werden, sobald das beschnittene Netz für eine Epoche trainiert hat. Es wird per Dreisatz berechnet wie groß die Batchgröße sein darf, bei gegebener maximaler Speicherauslastung. In Abbildung 5.6a ist zu sehen wie sich die durchschnittliche Trainingszeit pro Epoche entwickelt, bei Anpassung der Batchgröße. Für Abbildung 5.6a werden zwei verschieden große Lasso-Ratio Werte (LaR) $(0,2\text{und}0,25)$ getestet. Bei der Lasso-Ratio von $LaR = 0,25$ ergibt sich ein Gewinn an durchschnittlicher Trainingszeit pro Epoche. Zum Vergleich enthält die Abbildung auch die entsprechenden Experimente aus den Experimente zur Lasso-Ratio ohne Anpassung der Batchgröße. Die durchschnittliche Trainingszeit sinkt signifikant im Vergleich zum entsprechenden Experiment ohne Anpassung der Batchgröße, da mit einer höheren Batchgröße weniger Durchläufe gebraucht werden um die Epoche abzuschliessen. Für die Lasso-Ratio von $LaR = 0,25$ ergibt sich bei einem t-Test ein p-Wert von $p = 6.445 \cdot 10^{-05}$. Für die Lasso-Ratio von $LaR = 0,2$ ergibt sich bei einem t-Test ein p-Wert von $p = 0,0004$.
In Abbildung 5.6b ist zu sehen, wie gross der Accuracy-Verlust für das PruneTrain-Netz mit Anpassung der Batchgröße ist. Für PruneTrain mit einer Lasso-Ratio von 0,2 ergibt sich ein Accuracy Verlust von durchschnittlich 4,18 %. Für eine höhere Lasso-Ratio ergibt sich ein Accuracy-Verlust von 7,24 %. Diese Verluste sind wahrscheinlich auf eine nicht passende Anpassung der Lernrate in Abhängigkeit von der Änderung der Batchgröße zurückzuführen oder einer weniger häufigen Anpassung der Gewichte. Lernrate und Batchgröße hängen durch die ANzahl an Anpassungen der Gewichte zusammen: Steigt die Batchgröße, so werden weniger Durchläufe und damit weniger Gewichtsanpassungen durchgeführt. Um den geringeren zurück gelegten Weg in Richtung eines Minimum zu kopmensieren kann die Lernrate erhöht werden.

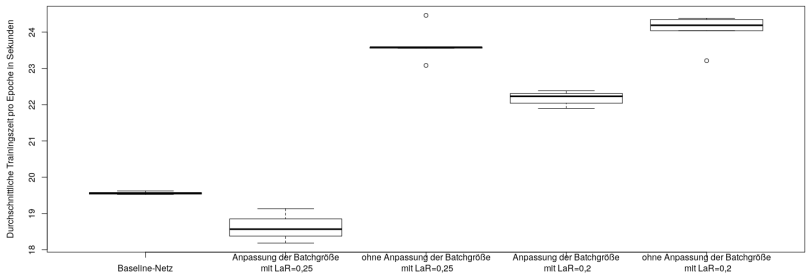

(a)

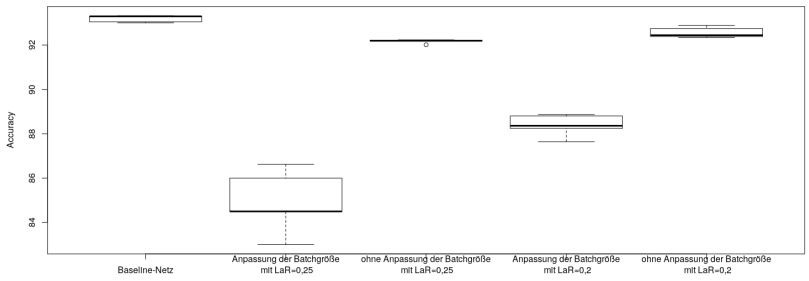

(b)

Abbildung 5.6: Vergleich von (a) Durchschnittlicher Trainingszeit (b) Accuracys von PruneTrain mit Anpassung der Batchgrößeund Baseline-Netz

6 Evaluierung von Net2Net

Die Operatoren zur Beschleunigung des Lernens durch Wissenstransfer werden in diesem Kapitel evaluiert. Diese Evaluierung arbeitet mit einer selbst erstellten Implementierung auf Grundlage der Veröffentlichung zum Thema Net2Net [CGS15].
Die Evaluierung umfasst drei unterschiedliche Situationen, diese Situation sind ähnlich, wie in der dazugehörigen Quelle [CGS15]. Die Evaluierung arbeitet mit einem ResNet, wie in Kapitel 3.1.4. In der Veröffentlichung wird mit einem Inception Net gearbeitet. Das Inception Netz wird in Kapitel 2.2.2 vorgestellt.
In der ersten Situation wird der Operator für ein breiteres Netz evaluiert, in dem das Netz breiter gemacht wird. In der zweiten Situation wird der Operator für ein tieferes Netz benutzt um zusätzliche Blöcke hinzuzufügen oder bestehenden Blöcken Schichten hinzuzufügen. In der dritten Situation werden beide Operatoren kombiniert. Mit der Kombination wird der Raum der möglichen Operatoranwendungen erkundet, ausgehend von einem Modell. Die drei Situationen werden in den drei folgenden Unterkapiteln näher beschrieben. Anpassungen der Lernrate werden hier nicht vorgenommen.

6.1 Evaluierung des Operators für ein breiteres Netz

Der Operator für ein breiteres Netz wird evaluiert, in dem ein schmalles Baseline-Netz für 90 Epochen trainiert wird. Dann wird der Operator angewendet. Nach der Anwendung wird für weitere 90 Epochen trainiert. Der Operator für ein breiteres Netz macht das Netz für diese Evaluierung doppelt so breit.
Wie in Kapitel 2.5 beschrieben werden beim Operator für ein breiteres Netz die Gewichte für die neu hinzugefügten Gewichte aus den ursprünglichen Gewichten ausgewählt und so normalisiert, dass die approximierte Funktion nach Anwendung des Operators nicht signifikant von der approximierten Funktion mit den neuen Gewichten abweicht. Um zu evaluieren wie gut diese Methode funktioniert wird sie auf das schmalle Baseline Netz angewendet und verglichen mit dem

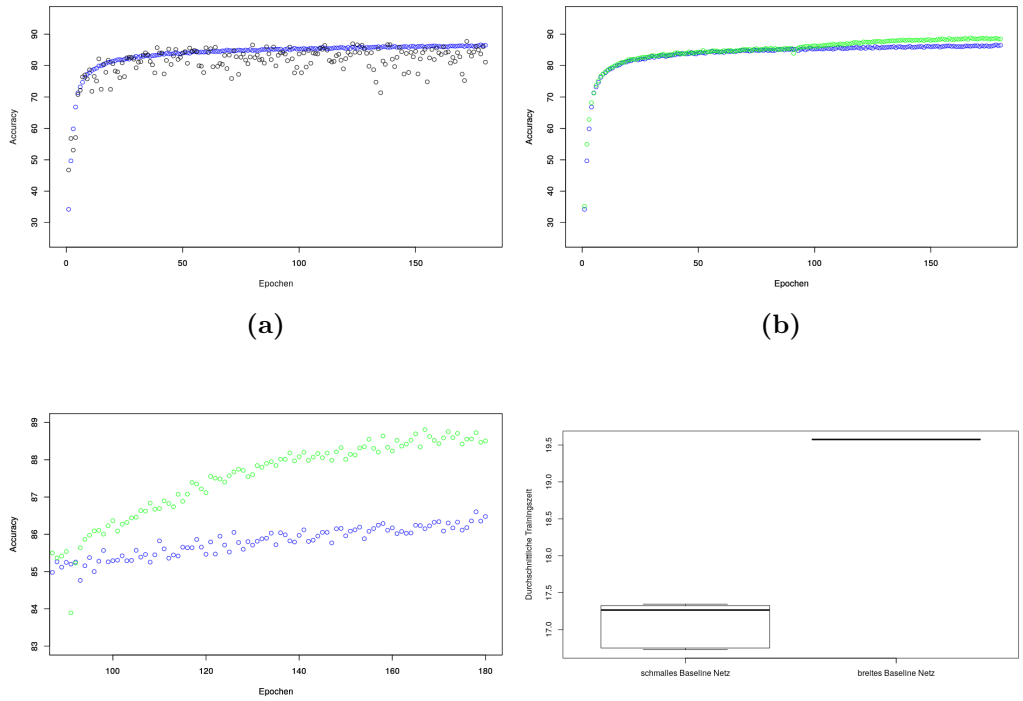

(a) **(b)**

(c) **(d)**

Abbildung 6.1

schmallen und breiten Baseline-Netz. Um die Methode der Initialisierung der zusätzlichen Kanäle zu evaluieren wird als Vergleich ein Netz trainiert, bei welchem die zusätzlichen Gewichte zufällig initialisiert werden.

In Abbildung 6.1a ist der Verlauf der Accuracy des schmallen Baseline Netzes in blau und des breiten Baseline Netzes in schwarz über 180 Epochen ohne Anpassung der Lernrate zu sehen. Es fällt auf, dass das schmalle Baseline Netz währenddem Training wesentlich stabiler trainiert als das breite. Allerdings ist das schmalle Baseline-Netz nach wenigen Epochen bereits so weit, dass es kaum Verbesserungen gibt. Auf das schmalle Baseline Netz wird im nächsten Schritt der Operator für ein breiteres Netz angewendet. In Abbildung 6.1b ist der Verlauf der Accuracy des schmallen Baseline Netzes in blau im Vergleich zum schmallen Baseline Netz mit Anwendung des Operators in grün zu sehen. In Abbildung 6.1c ist ein Ausschnitt von Abbildung 6.1b für die Epochen 90 -180 zu sehen. An den beiden Grafiken ist eindeutig abzulesen, dass der Operator für ein breiteres Netz auf dem Baseline Netz die Accuracy verbessert. Die Verbesserung liegt bei den verglichenen Durchläufen bei 2 %.

Gegenüber dem breiten Baseline Netz spart dieses Training mit dem Operator da-

durch Zeit, dass in den ersten 90 Epochen weniger Trainingszeit verbraucht wird. In Abbildung 6.1d ist die durchschnittliche Trainingszeit des schmallen Baseline Netz verglichen mit dem breiten in einem Boxplot zu sehen. Bei der hier verwendeten Größe des Netzes dauert die Anwendung des Operators für ein breiteres Netz etwa 0,3 Sekunden. Damit liegt die Trainingszeit des Netzes mit Anwendung des Operators zwischen schmallen und breiten Baseline-Netz.
Bei dem hier verwendeten Netz und Datensatz macht die Anwendung des Operators Sinn, dass sie das Training stabiler, schneller und besser macht.

6.2 Evaluierung des Operators für ein tieferes Netz

Zur Evaluierung des Operators für ein tieferes Netz wird zunächst wie in der Veröffentlichung jeder Block um eine Schicht erweitert. Dafür wird mit einem Netz gestartet, welches jeweils nur eine Convolution und Batchnormalisation Schicht pro Block hat ($l = 1$).
Dabei werden die zusätzlichen Schichten wie in Kapitel 2.5 beschrieben initialisiert. Als Vergleich dient das Baseline-Netz aus Kapitel 3.1.4. Ein weiterer Vergleichspunkt ist das Netz, mit welchem trainiert wird beovr der Operator abgewendet wird. Dieses Netz wird zusätzlich über 180 Epochen trainiert, um die Auswirkungen des Operators zu sehen. Die Accuracy des Ausgangsnetzes ist in Abbildung zu sehen. Zu beobachten ist, dass das Augangsnetz auch unstabil trainiert.

ref

Wird in Epoche 90 der Operator für ein tieferes Netz angewendet, so wird im Gegensatz zum Operator für ein breiteres Netz danach ein deutliches Abfallen der Accuracy auf unter 30 % beobachtet. Allerdings lässt sich hier auch eine leicht erhöhte Stabilität des Trainings beobachten. Dies ist Abbildung **??** in grün abgebildet. Die blaue Kurve in Abbildung **??** zeigt eine andere Initialisierungsmethode. Diese fügt zusätzlich noch eine normalverteilte Störung mit $\mu = 0, \sigma^2 = 0.1$,den Gewichten die gleich Null sind nach der Initialisierung, hinzu.
Zu beobachten ist, dass das Netz von vorne anfängt zu trainieren. Trotz dieses Problem wird Zeit gespart, durch die schnellere Trainingszeit bis zum Anwenden des Operators. Da beim Ausgangsnetz bereits recht schnell keine Verbesserung auftritt zeigt Abbildung **??** das Ergebnis bei Anwendung des Operators in Epoche 50. Es zeigt sich, dass bei der Verwendung dieser Netzstruktur auf dem Datensatz Cifar10 keine wesentliche Verbesserung gegenüber der Netzstruktur nachdem Anwenden des Operators ergibt. Es ergibt sich jedoch eine Verbesserung gegenüber

dem Ausgangsnetz und die Stabilität des Trainings steigt.
Eine weitere Verwendung des Operators für ein tieferes Netz ist die Möglichkeit einen neuen Block hinzuzufügen. Nur ein einfaches Hinzufügen würde hier zu Problemen führen, da durch das Hinzufügen eines Blockes die vom Netz berechnete Funktion von der vorher berechneten Funktion abweicht. Gelöst wird dies, in dem alle Blöcke vor der Addition mittels eines muliplikativen Faktors skaliert werden. Wie in Abbildung abgebildet ist, wird alle muliplikativen Faktoren des Ausgangsnetzes auf 1 gesetzt, sodass hier kein Effekt auf die berechnende Funktion entsteht. Beim neu hinzuzufügenden Block werden die beiden multiplikativen Faktoren auf 0,5 gesetzt. Da der neu hinzuzufügende Block ein Identitätsblock ist wird das Ergebnis des Identitätsblockes und der Kurzschlussverbindung zusammen keinen Effekt auf die vom Netz berechnete Funktion haben. In Abbildung **??** ist zu sehen, wie der neue Block in das Gefüge der anderen Blocks passt.
In Abbildung ist abgebildet, wie sich die Accuracy eines Netzes mit den multiplikativen Faktoren über 180 Epochen verhält.

ref

ref

6.3 Erkunden des Modellraums

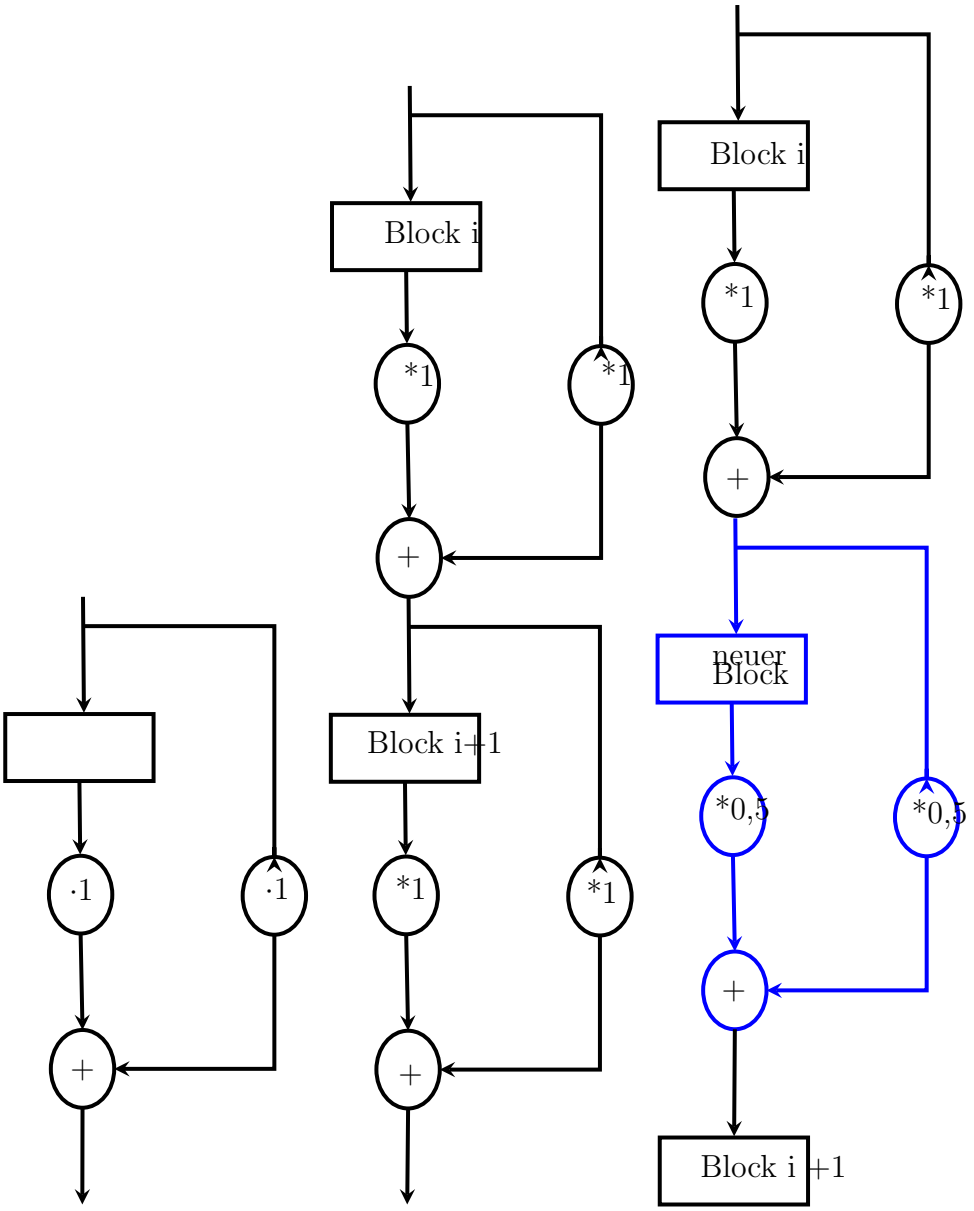

(a) Diagramm 1 **(b)** Diagramm 2 **(c)** Diagramm 3

Abbildung 6.2

(a)

Abbildung 6.3: Vergleich von

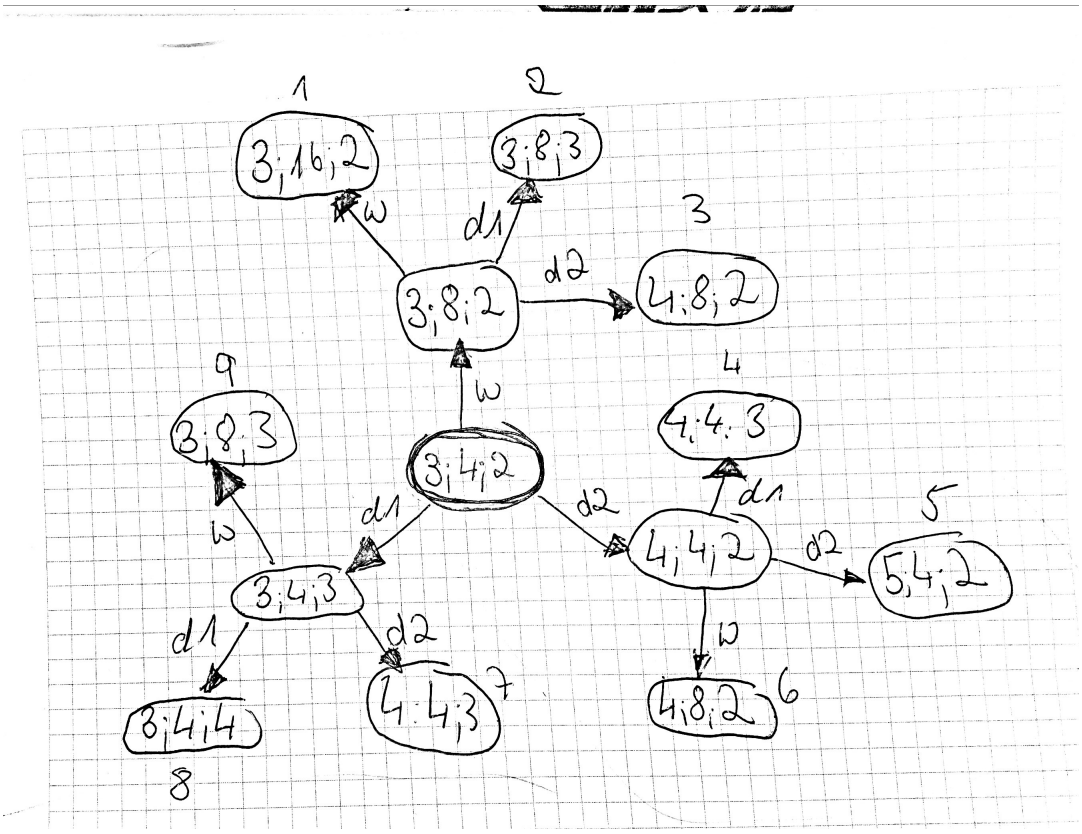

(a)

Abbildung 6.4: Anzahl an Blöcken pro Phase; Breite der ersten Schicht; Schichten pro Block

7 Ausblick und Fazit

Es hat sich gezeigt, dass MorphNet den Nachteil hat, dass die Tiefe des Netzes nicht verändert werden kann. Diesen Nachteil kann Net2Net als potentieller Kandidat einer erweiternden Methode einer Kombination ausgleichen. Es zeigt sich bei allen Verfahren, dass eine Anpassung der Lernrate Sinn macht.
Es wäre sowohl für MorphNet als auch für die Kombination ein potentieller Gewinn, wenn die Lernrate automatisch angepasst werden würde, bevor eine Anpassung der Struktur passiert. Der Grund, wieso dies sinnvoll ist liegt daran, dass ohne Anpassung der Lernrate nicht das volle Potential jedes Modells genutzt werden kann. Hierwäre es allerdings notwendig nach der Veränderung der Struktur zu evaluieren, wie mit der Lernrate weiter zu verfahren ist. Die Anpassung der Lernrate sollte hier sowohl bei einem Plateau in der Accuracy als auch bei nicht stabilen Training funktionieren.
Da sich beim Training der verschiedenen Netze gezeigt hat, dass diese unterschiedlich lange brauchen, um ihr Potential auszuschöpfen ist es sinnvoll die Epoche zu der ein Operator von Net2Net angewendet wird flexibel anhand des Accuracy Verlaufs zu gestalten.
Bei den verschiedenen Verfahren ist zu beobachten, dass in allen vorgestellten Fällen ein Trade-off zwischen Accuracy und Trainingszeit zu beobachten ist.

Abbildungsverzeichnis

Literaturverzeichnis

[CCGS16] J.F. Couchot, R. Couturier, C. Guyeux, and M. Salomon. Steganalysis via a convolutional neural network using large convolution filters. *CoRR*, 2016.

[CDZM20] Ting-Wu Chin, Ruizhou Ding, Cha Zhang, and Diana Marculescu. Towards efficient model compression via learned global ranking, 2020.

[CGS15] Tianqi Chen, Ian Goodfellow, and Jonathon Shlens. Net2net: Accelerating learning via knowledge transfer. 11 2015.

[DZZZ20] Hongwei Dong, Bin Zou, Lamei Zhang, and Siyu Zhang. Automatic design of cnns via differentiable neural architecture search for polsar image classification. *IEEE Transactions on Geoscience and Remote Sensing*, 2020.

[FC19] Jonathan Frankle and Michael Carbin. The lottery ticket hypothesis: Finding sparse, trainable neural networks. In *ICLR*, 2019.

[GBC16] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learningo*. MIT Press, 2016. `http://www.deeplearningbook.org`.

[GEN+18] A. Gordon, E. Eban, O. Nachum, B. Chen, H. Wu, T. Yang, and E. Choi. Morphnet: Fast simple resource-constrained structure learning of deep networks. In *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2018.

[Hay98] S. Haykin. *Neural Networks: A Comprehensive Foundation*. Prentice Hall PTR, Upper Saddle River, NJ, USA, 2nd edition, 1998.

[HZRS15] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *CoRR*, 2015.

[iee85] Ieee standard for binary floating-point arithmetic. *ANSI/IEEE Std 754-1985*, 1985.

[IS15] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *Proceedings of the 32nd International Conference on International Conference on Machine Learning - Volume 37*, ICML'15, page 448–456. JMLR.org, 2015.

[LCZ+19] Sangkug Lym, Esha Choukse, Siavash Zangeneh, Wei Wen, Mattan Erez, and Sujay Shanghavi. Prunetrain: Gradual structured pruning from scratch for faster neural network training. *CoRR*, abs/1901.09290, 2019.

[MAL+19] Guillaume Michel, Mohammed Amine Alaoui, Alice Lebois, Amal Feriani, and Mehdi Felhi. DVOLVER: efficient pareto-optimal neural network architecture search. *CoRR*, abs/1902.01654, 2019.

[oA19] ohne Autor. arxiv machine learning classification guide, 12 2019. Onlinequelle; Aufgerufen am 01.06.2020; `https://blogs.cornell.edu/arxiv/2019/12/05/arxiv-machine-learning-classification-guide/`.

[ptI] Prune train implementierung. online `https://bitbucket.org/lph_tools/prunetrain/src/master/`aufgerufen am 10.06.2020.

[SG17] Charles A. Sutton and Linan Gong. Popularity of arxiv.org within computer science. *CoRR*, 2017.

[SXZ+20] Yanan Sun, Bing Xue, Mengjie Zhang, Gary G Yen, and Jiancheng Lv. Automatically designing cnn architectures using the genetic algorithm for image classification. *IEEE Transactions on Cybernetics*, 2020.

[TKYG20] Hidenori Tanaka, Daniel Kunin, Daniel L. K. Yamins, and Surya Ganguli. Pruning neural networks without any data by iteratively conserving synaptic flow, 2020.